

«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)»
(МАИ)

ФАКУЛЬТЕТ №
КАФЕДРА

**ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К ДИПЛОМНОМУ ПРОЕКТУ**

На тему: _____

Дипломант: _____
(фамилия, имя, отчество) (подпись)

Руководитель проекта: _____
(фамилия, имя, отчество) (подпись)

Консультанты:

по спец. части: _____
(фамилия, имя, отчество) (подпись)

по технологической части: _____
(фамилия, имя, отчество) (подпись)

по экономической части: _____
(фамилия, имя, отчество) (подпись)

по охране труда: _____
(фамилия, имя, отчество) (подпись)

Рецензент: _____
(фамилия, имя, отчество) (подпись)

Москва 200__год

«УТВЕРЖДАЮ»
Зав. кафедрой

Московский авиационный институт
(национальный исследовательский университет)»
(МАИ)

«__» _____ 20__ года.

Факультет _____ 3 _____
Кафедра _____ 308 _____

ЗАДАНИЕ
по подготовке дипломного проекта (работы)

Студенту _____ Панченко Владимиру Владимировичу _____

1. Тема проекта (работы) Разработка системы мониторинга состояния ЛА (Integrated System Health Management) на основе методов интеллектуального анализа данных (Data Mining)
2. Срок сдачи студентом законченного проекта (работы) 15 декабря _____ 2013__ года
3. Исходные данные к проекту (работе) данные телеметрии или их модель, алгоритмы интеллектуального анализа данных (Data Mining), модель распределённых вычислений MapReduce, алгоритмы выявления аномалий без учителя (Orca, GritBot, IMS, one-class SVM)
4. Перечень вопросов, подлежащих разработке в дипломном проекте, или краткое содержание дипломной работы:

№№ п/п	Разрабатываемый вопрос	Срок выполнения
	Обоснование актуальности разработки системы. Методы интеллектуального анализа данных как средство повышения эффективности систем мониторинга.	10.11.2013
1	Специальная часть	
1.1	Анализ существующих алгоритмов выявления аномалий без учителя	15.11.2013
1.2	Разработка метода мониторинга состояния ЛА на основе методов интеллектуального анализа данных	20.11.2013
1.3	Выбор программных средств реализации метода	25.11.2013
1.4	Разработка программной реализации метода	10.12.2013
1.5	Анализ результатов	12.12.2013
2	Экономическая часть	12.12.2013
3	Охрана труда и окружающей среды	12.12.2013

5. Перечень графического материала (с точным указанием обязательных чертежей):

[illegible]

6. Консультанты по проекту (работе)

по спец. части

(фамилия, инициалы)

(подпись)

по экономической части

(фамилия, инициалы)

(ПОДПИСЬ)

по охране труда

(фамилия, инициалы)

(ПОДПИСЬ)

по технологической части

(фамилия, инициалы)

(подпись)

7. Дата выдачи задания _____

Руководитель

(подпись)

Задание принял к исполнению

(дата)

Подпись студента _____

РЕФЕРАТ

Панченко В.В. РАЗРАБОТКА СИСТЕМЫ МОНИТОРИНГА СОСТОЯНИЯ ЛА (INTEGRATED SYSTEM HEALTH MANAGEMENT) НА ОСНОВЕ МЕТОДОВ ИНТЕЛЛЕКТУАЛЬНОГО АНАЛИЗА ДАННЫХ (DATA MINING), дипломная работа: 76 с., 15 рис., 19 табл., 47 ист., 8 прил.

Ключевые слова: DATA MINING, ПОИСК АНОМАЛИЙ, КЛАСТЕРИЗАЦИЯ, INTEGRATED SYSTEM HEALTH MONITORING

Содержание

Введение	6
1 Специальная часть	10
1.1 Постановка задачи	10
1.2 Анализ существующих методов выявления аномалий без учителя	10
1.2.1 Orca	11
1.2.2 GritBot	13
1.2.3 GMM (Gaussian Mixture Model)	16
1.2.4 DBN (Dynamic Bayesian Network)	19
1.2.5 One-Class SVM (Support Vector Machine)	24
1.2.6 Inductive Monitoring System (IMS)	27
1.3 Разработка метода мониторинга состояния ЛА на основе методов интеллектуального анализа данных	30
1.3.1 Формальная постановка задачи мониторинга системы	30
1.3.2 Описание метода	32
2 Расчет экономической эффективности системы	37
2.1 Введение	37
2.2 Определение целесообразности разработки	37
2.3 Определение трудоемкости и затрат на создание ПП	38
2.4 Определение исполнителей	40
2.5 Расчет заработной платы исполнителей	40
2.6 Социальные отчисления	41
2.7 Накладные расходы	42
2.8 Прочие расходы	42
2.9 Расчет стоимости	42
2.10 Оценка экономической эффективности	43
2.11 Календарное планирование	44
2.12 Выводы	46

3 Охрана труда и окружающей среды	48
3.1 Анализ условий труда	48
3.1.1 Обеспечение условий труда в отделе разработки программного обеспечения	48
3.1.2 Характеристика помещения	48
3.1.3 Характеристика производственного процесса	49
3.1.4 Характеристика используемого оборудования	50
3.1.5 Санитарно-гигиенические факторы	50
3.1.6 Электроопасность	53
3.1.7 Пожароопасность	53
3.1.8 Эргономические факторы	54
3.1.9 Психофизиологические факторы	56
3.2 Мероприятия по обеспечению условий труда	58
3.3 Расчетная часть	59
3.3.1 Расчет уровня шума	59
3.4 Вывод	61
Заключение	63
Список использованных источников	64
Приложение А Блок-схема ЕМ-алгоритма для GMM	69
Приложение Б Блок-схема процесса обучения IMS	70
Приложение В Блок-схема процесса мониторинга IMS	71
Приложение Г Блок-схема процесса обучения разрабатываемого метода	72
Приложение Д Блок-схема процесса создания базы кластеров для каждого режима работы системы (для разрабатываемого метода)	73
Приложение Е Блок-схема процесса обучения разрабатываемого метода	74
Приложение Ж Исходный код	75
Приложение З Графические материалы	76

Введение

Одной из ключевых проблем при эксплуатации летальных аппаратов (ЛА) является контроль и своевременная диагностика неисправностей. Подобный контроль выполняется на основе информации, поступающей с датчиков, контролирующих работу устройства. Для решения подобных задач используются системы ISHM (Integrated System Health Management) позволяющие оценить текущее и/или будущее состояние здоровья системы и интегрировать эту информацию в общую картину эксплуатационных потребностей с учётом имеющихся ресурсов [1]. В ISHM состояние системы контролируется по показаниям датчиков. Прогресс в развитии микроэлектроники за последние 10–15 лет привел к тому, что датчики стали существенно дешевле, легче и меньше по размерам. Это вызвало увеличение количества используемых датчиков и рост объемов телеметрической информации. Естественно, ручная обработка больших объемов информации слишком трудоемка — нужны средства автоматизации.

Традиционно системы ISHM используют одновременно несколько методов диагностики, в частности [2]:

- проверку выхода значения параметра за установленные пределы;
- экспертную систему, содержащую набор правил, описывающих нормальное поведение системы (rule-based);
- математическую модель, описывающую требуемое поведение системы (model-based).

Общий принцип у традиционных алгоритмов примерно один и тот же. Вначале эксперты задают модель поведения системы, представляющую набор правил, характеризующих поведение системы. В процессе работы системы поступающие телеметрические данные проверяются на соответствие модели. Если поведение данных начинает отклоняться от модели, то оператору, контролирующему работу системы, поступает тревожный сигнал о возможной неисправности.

У всех традиционных алгоритмов есть общий недостаток — они требуют интенсивной работы экспертов. Эксперты задают набор правил, конструируют математическую модель, устанавливают допустимые пределы значений параметров. Возрастает количество данных — возрастает количество работы, которую необходимо проделать экспертам, прежде чем система мониторинга сможет работать.

Данную задачу возможно автоматизировать средствами интеллектуального анализа данных — Data Mining. Это собирательное название, используемое для обозначения совокупности методов обнаружения в данных ранее неизвестных, нетривиальных, практически полезных и доступных интерпретации знаний, необходимых для принятия решений в различных сферах человеческой деятельности [3]. Фактически Data Mining — это набор технологий поиска скрытых закономерностей в больших необработанных объемах данных. Data Mining является частью процесса KDD (Knowledge Discovering in Databases), включающем, помимо поиска закономерностей, этапы сбора, подготовки данных и последующего анализа полученных результатов. К настоящему времени разработано множество алгоритмов и технологий Data Mining. Характерно, что универсального алгоритма для извлечения знаний из данных не существует. Каждое конкретное практическое приложение, обладающее специфическими характеристиками, требует либо адаптации существующих методик Data Mining, либо разработки новой технологии обработки данных.

Одним из ключевых направлений применения технологий Data Mining является автоматизация поиска аномалий. Поиск аномалий — это поиск шаблонов данных, не соответствующих ожидаемому поведению [4]. Хоукинс [5] определяет аномалию как «наблюдение, отличающееся от остальных настолько, что даёт основание полагать, что оно было сгенерировано с помощью другого метода или механизма». Поиск аномалий широко применяется в задачах мониторинга состояния технических систем [6]. Если в работе системы возникает неисправность, в данных, поступающих с датчиков, возникают аномалии, сигнализирующие об отклонении поведения системы от нормального поведения. Типичными задачами, решаемыми подобными системами мониторинга, являются определение факта возникновения аномалии, локализация ее местонахождения, диагностирование возникшей неисправности и прогнозирование возникновения неисправностей.

Методы диагностики аномалий, основанные на Data Mining (data-driven методы), свободны от недостатков традиционных методов и не требуют интенсивного участия экспертов для своей работы. Data-driven методы строят модель поведения системы автоматически на основе данных о нормальном поведении системы. Для обучения таким методам обычно достаточно несколько сотен точек нормальных данных.

Data-driven методы имеют ряд преимуществ по сравнению с традиционными:

- не требуют априорно заданных знаний о работе системы;
- не требуют системного анализа, чтобы определить соотношения между параметрами;
- способны обрабатывать телеметрические данные, поступающие от работающей системы, в режиме реального времени и быстро реагировать на появление аномалии, т.к. модель поведения системы очень компактна;
- позволяют устанавливать и отслеживать взаимосвязь между большим количеством параметров;
- способны обнаруживать коллективные и контекстные аномалии [4];
- дают возможность автоматически обрабатывать архивы накопленных данных и извлекать из них полезную информацию;
- позволяют легко учитывать новые данные о нормальном поведении системы и обновлять ранее построенную модель её поведения.

Разработки систем мониторинга неисправностей на основе методов Data Mining активно ведутся в Японии [2] и США [7, 8]. В последние годы за рубежом был разработан ряд data-driven методов и алгоритмов обнаружения аномалий, например, Orca, GritBot, IMS, GMM, LVS, одноклассовый SVM и др. Как показано в [9], результаты работы разных методов могут отличаться, поэтому целесообразно их комбинировать.

Наиболее весомым доказательством эффективности ISHM-систем на основе данных методов в аэрокосмической отрасли является их успешное применение в NASA для диагностики неисправностей в ЛА типа «Шаттл» и их преемниках — серии «Ares» [7]. Пробный пуск системы на архивных данных показал, что установка такой системы на аппарате «Колумбия» серии «Шаттл» позволила бы избежать взрыва ЛА при посадке, повлёкшего гибель всего экипажа. Как известно, «Колумбия» потерпела катастрофу из-за отрыва куска изоляционной обшивки, пробившей термоизоляцию на левом крыле. Отрыв произошел во время старта корабля, однако о проблемах с термоизоляцией стало известно лишь через 17 дней, во время приземления шатла [10]. База знаний ISHM строилась на основе анализа данных предыдущих 5 полетов «Колумбии». ISHM выдала сигнал о возникновении неисправности в течении двух минут с момента ее возникновения [6, 8]. В данной системе совместно используются методы Orca и IMS [11].

Подобные системы нашли применение на Международной Космической Стан-

ции (МКС) для контроля работоспособности и определения сроков ремонта и замены гироскопов (гироскоп, англ. control moment gyroscope, сокр. CMG — вращающееся инерциальное устройство, применяемое для высокоточной ориентации и стабилизации, как правило, космических аппаратов (КА), обеспечивающее правильную ориентацию в полете и предотвращающее беспорядочное вращение [12]). С 2008 года NASA ведёт работы по применению данных методов для контроля и диагностики других подсистем МКС [11].

Japan Aerospace Exploration Agency (Японское агентство аэрокосмических исследований) с 2011 года ведёт разработку систем мониторинга состояния спутников на основе данных телеметрии. Основным используемым методом в данной системе является SVM [13].

Таким образом, является перспективным разработать ISHM-систему на основе методов интеллектуального анализа данных, представляющую функционал, аналогичный зарубежным, но являющуюся открытой и доступной для использования в отечественных разработках.

1 Специальная часть

1.1 Постановка задачи

Разработать метод мониторинга состояния ЛА на основе методов интеллектуального анализа данных. Реализовать программную систему, использующую данный метод.

Система должна удовлетворять следующим требованиям:

- строить модель системы только на основе телеметрии при различных режимах её работы, без априорных данных о предметной области, назначении системы, её составе, конструкции (обучение без учителя);
- обладать способностью классифицировать аномалии в работе системы;
- в случае, если текущее поведение системы не было представлено в обучающей выборке, давать оператору численную характеристику отклонения системы от номинальных режимов;
- обрабатывать большие массивы входных данных (несколько десятков тысяч точек) за конечное время;
- учитывать как непрерывные, так и дискретные параметры системы;
- не иметь ограничений на закон распределения входных данных;
- быть устойчивой к аномалиям в обучающей выборке;
- быть устойчивой к отсутствию значений каких-либо параметров во входных данных;
- определять состояние системы в режиме реального времени.

1.2 Анализ существующих методов выявления аномалий без учителя

На данный момент существует несколько методов, для которых доказана возможность применения их в системах контроля и диагностики ЛА. Такими методами являются Orca, GritBot, GMM (Gaussian Mixture Model), DBN (Dynamic Bayesian Network), One-Class SVM (Support Vector Machine) и IMS (Inductive Monitoring System) [9].

1.2.1 Orca

Orca — метод поиска аномалий без учителя, использующий подход «ближайшего соседа» (nearest neighbor) для поиска аномалий [14]. Данный метод был разработан Стефеном Бэйем (Institute for the Study of Learning and Expertise) и Марком Швабахером (NASA Ames Research Center) и подробно описан в [15]. Orca относится к методам обнаружения аномалий, основанных на измерении расстояний между точками (distance-based).

Понятие аномалии для данного класса методов определено следующим образом: «объект O в выборке T является аномалией, если по крайней мере доля p из всех объектов в T лежит дальше от O , чем расстояние D » [16]. Distance-based методы являются обобщением некоторых статистических тестов на аномальность. Данный класс методов не требует априорных знаний о виде распределения для выборки. Кнорр и Нг предложили простейший алгоритм на вложенных циклах (Nested Loop, NL) [16], который находит аномалии путём вычисления расстояния между всеми точками в исходной выборке. Сложность данного алгоритма составляет $O(kN^2)$, где k — размерность пространства, а N — размер выборки.

Несмотря на то, что были разработаны более эффективные с т.з. вычислительной сложности алгоритмы ([17] и [18]), на практике наиболее сложным является определение расстояния D , по достижению которого точку следует считать аномалией. Может потребоваться непредсказуемо большое число итераций, чтобы найти подходящее значение D . Найти интервал $[D_{min}, D_{max}]$ возможно путём полного перебора, как показано в [17], но данный подход обладает слишком высокой вычислительной сложностью.

В качестве решения данной проблемы было предложено следующее определение аномалии, не требующее задания D : «объект считается аномалией, если это один из n объектов с наибольшим расстоянием до их k -ых ближайших соседей, где $k, n \in \mathbb{N}$ » [19]. Пользователю достаточно указать количество аномалий, которое должен вернуть алгоритм, без прямого указания дистанции D . Более того, возвращаемые алгоритмом аномалии будут ранжированы по степени аномальности, являющейся численной характеристикой.

Orca использует данный подход, развивая идею алгоритма на вложенных циклах (NL). Данный алгоритм на больших массивах данных показывает сложность, близ-

кую к линейной [15].

Псевдокод алгоритма приведён в листинге 1. Ключевыми особенностями алгоритма являются:

- необходимость рандомизации исходных данных (строка 1). Для эффективной работы алгоритма требуется, чтобы объекты в выборке находились в случайном порядке. При обработке выборки на ПЗУ возможно рандомизировать выборку за линейное время и используя конечный объём памяти [15];
- использование вложенных циклов (строка 5). Основной идеей является отслеживание ближайших соседей для каждого объекта в D ;
- правило отсечения (строка 11). Когда для ближайших соседей объекта степень аномальности становится меньше, чем величина среза, алгоритм удаляет данный объект, так как больше нет оснований считать его аномальным. Чем больше объектов перебирает алгоритм, тем выше становится величина среза, улучшая таким образом эффективность алгоритма по времени.

В качестве метрики для определения расстояния может использоваться, к примеру, Евклидово расстояние для непрерывных и расстояние Хэмминга для дискретных переменных. Функция, определяющая степень аномальности, может быть любой монотонно убывающей функцией от расстояний до ближайших соседей [15], например, среднее расстояние до k ближайших соседей или расстояние до k -го ближайшего соседа.

Преимуществами метода являются:

- превосходная масштабируемость: на выборках большого объёма производительность алгоритма близка к линейной;
- низкие требования к памяти: не требуется загружать в память всю выборку;
- возможность задать любую метрику для расстояния и функцию для определения степени аномальности.

Недостатки следуют из природы метода. В качестве основных можно выделить следующие:

- в худшем случае (например, когда выборка не содержит аномалий) производительность алгоритма крайне низкая. Из-за вложенных циклов может потребоваться $O(N^2)$ операций вычисления расстояния и $O(N/l \cdot N)$ операций доступа к данным, где l — размер буфера;

Листинг 1 — Псевдокод алгоритма Orca

Входные данные: k , количество ближайших соседей; n , количество аномалий; D , выборка.

Выходные данные: O , множество аномалий

- 1: Перемешать все объекты в выборке D .
 - 2: Инициализировать величину среза нулём.
 - 3: **до тех пор, пока** в выборке D остались необработанные объекты **выполнять**
 - 4: Загрузить фиксированное количество объектов B в буфер.
 - 5: **для** каждого объекта d в D **выполнять**
 - 6: **для** каждого объекта b в B **выполнять**
 - 7: Вычислить расстояние между b и d .
 - 8: **если** d ближе к b , чем k ближайших соседей b **то**
 - 9: Заменить соседа с наибольшим расстоянием на d .
 - 10: Вычислить степень аномальности b .
 - 11: **если** степень аномальности ниже величины среза **то**
 - 12: Удалить b из B .
 - 13: **конец**
 - 14: **конец**
 - 15: **конец цикла**
 - 16: **конец цикла**
 - 17: Поместить в O оставшиеся в B объекты.
 - 18: Отсортировать объекты в O по степени аномальности.
 - 19: Оставить в O только n объектов.
 - 20: Обновить величину среза степенью аномальности последнего объекта в O .
 - 21: **конец цикла**
 - 22: **вернуть как результат** O .
-

- в качестве результата алгоритм возвращает фиксированное число аномалий, указанное перед началом работы;
- данный метод не способен определять аномальность объекта в реальном времени, так как для этого требуется вычислить расстояние до всех объектов в выборке.

1.2.2 GritBot

GritBot является коммерческим продуктом компании RuleQuest Research [20]. Вместо поиска точек, наиболее сильно отличающихся от остальной выборки, данный метод ищет подмножества, аномальность которых очевидна [14]. Метод определяет

границы для непрерывных и список возможных значений для дискретных переменных, формируя набор правил классификации. GritBot основан на использовании деревьев решений [9] и использует алгоритм C4.5 [21], разработанный Джоном Квинланом и описанный им в [22].

Для того, чтобы с помощью C4.5 построить дерево решений и применять его, входные данные должны удовлетворять нескольким условиям.

Информация об объектах, которые необходимо классифицировать, должна быть представлена в виде конечного набора признаков (атрибутов), каждый из которых имеет дискретное или непрерывное значение. Такой набор атрибутов назовём *примером*. Для всех примеров количество атрибутов и их состав должны быть постоянными.

Множество классов, на которые будут разбиваться примеры, должно иметь конечное число элементов, а каждый пример должен однозначно относиться к конкретному классу. Для случаев с нечёткой логикой, когда примеры принадлежат к классу с некоторой вероятностью, C4.5 неприменим.

В обучающей выборке количество примеров должно быть значительно больше количества классов, к тому же каждый пример должен быть заранее ассоциирован со своим классом. По этой причине C4.5 является вариантом машинного обучения с учителем.

Данный алгоритм рекурсивно разбивает множество объектов на подмножества так, чтобы энтропия полученных подмножеств была минимальна. Лучшее разбиение при этом выбирается перебором всех возможных вариантов.

Построение дерева решений в алгоритме C4.5 происходит следующим образом. Пусть имеется T — обучающая выборка примеров, а C — множество классов, состоящее из k элементов. Для каждого примера из T известна его принадлежность к какому-либо из классов $C_1 \dots C_k$.

На первом шаге имеется корень и ассоциированное с ним множество T , которое необходимо разбить на подмножества. Для этого необходимо выбрать один из атрибутов в качестве проверки. Выбранный атрибут A имеет n значений, что даёт разбиение на n подмножеств. Далее создаются n потомков корня, каждому из которых поставлено в соответствие своё подмножество, полученное при разбиении T . Процедура выбора атрибута и разбиения по нему рекурсивно применяется ко всем n потомкам и останавливается в двух случаях:

- после очередного ветвления в вершине оказываются примеры из одного класса (тогда она становится *листом* дерева, а класс, которому принадлежат её примеры, будет решением листа);
- вершина оказалась ассоциированной с пустым множеством (тогда она становится листом, а в качестве решения выбирается наиболее часто встречающийся класс у непосредственного предка этой вершины).

Пример дерева решений, построенного алгоритмом C4.5, приведён на рисунке 1.




Рисунок 1 — Пример дерева решений

Так как алгоритм C4.5 относится к машинному обучению с учителем, GritBot дополняет его механизмом автоматического определения классов на основе вычисления статистических свойств выборки.

В исследовании [21] GritBot показал крайне низкую эффективность, не найдя ни одной добавленной в выборку аномалии. Это связано со статистическим подходом к определению аномальности объекта (метод ищет корреляцию между параметрами объектов в выборке).

К преимуществам можно отнести лёгкость интерпретации результатов человеком (из-за использования деревьев решений можно получить набор правил, по которым пример был признан аномальным).

Недостатки:

- низкая эффективность при наличии в выборке объектов с большим числом аномальных параметров [21];
- данный метод загружает весь массив исходных данных в память [15]; таким образом, с его помощью невозможно обрабатывать сколь-либо большие выборки;
- нет численной оценки степени аномальности примера (метод сортирует аномалии по их статистической значимости) [9].

1.2.3 GMM (Gaussian Mixture Model)

GMM, или модель гауссовых смесей, наследует идеи байесовских сетей в том смысле, что она может быть легко представлена в рамках парадигмы графического моделирования.

Пример графической модели, представляющей гауссову смесь, показана на рисунке 2. Здесь $q_k \in \{1, \dots, M\}$, $\theta = (\pi_1, \dots, \pi_M, \mu_1, \dots, \mu_M, \Sigma_1, \dots, \Sigma_M)$. Закрашенные узлы представляют наблюдаемые непрерывные переменные, y_k для момента времени k . Незакрашенные узлы, q_k , представляют M ненаблюдаемых дискретных переменных, условная вероятность которых может быть вычислена на основе наблюдаемых данных. Параметры, содержащие θ , могут быть выражены как функция от этих условных вероятностей и от других похоже сформированных оценок для каждой из M гауссовых смесей, включая весовые коэффициенты смесей (π_i), математические ожидания (μ_i) и матрицы ковариации (Σ_i).




Рисунок 2 — Графическое представление GMM без учителя

Для использования данного метода требуется выполнение двух гипотез, пред-

ставленных ниже.

Гипотеза о природе данных: тестовые примеры появляются случайно и независимо, согласно вероятностному распределению, равному смеси распределений кластеров. Данное условие отображено в формуле (1).

$$p(x) = \sum_{c \in C} w_c p_c(x), \sum_{c \in C} w_c = 1, \quad (1)$$

где w_c — вероятность появления объектов из кластера c ;

p_c — плотность распределения кластера c .

Гипотеза о форме кластеров: каждый кластер c описывается d -мерной гауссовской плотностью с центром $\mu_c = \{\mu_{c1}, \dots, \mu_{cd}\}$ и диагональной матрицей ковариации $\Sigma_c = \text{diag}(\sigma_{c1}^2, \dots, \sigma_{cd}^2)$ (т.е. по каждой координате своя дисперсия).

В этих предположениях для определения аномалий получается задача разделения смеси гауссовых распределений. Для этого обычно используется ЕМ-алгоритм (expectation-maximization) [9]. Подробное описание данного алгоритма представлено в [23].

ЕМ-алгоритм используется в математической статистике для нахождения оценок максимального правдоподобия параметров вероятностных моделей, в случае, когда модель зависит от некоторых скрытых переменных. Каждая итерация алгоритма состоит из двух шагов. На *E-шаге* (*expectation*) вычисляется ожидаемое значение функции правдоподобия, при этом скрытые переменные рассматриваются как наблюдаемые. На *M-шаге* (*maximization*) вычисляется оценка максимального правдоподобия, таким образом увеличивается ожидаемое правдоподобие, вычисляемое на Е-шаге. Затем это значение используется для Е-шага на следующей итерации. Алгоритм выполняется до сходимости.

Формальная постановка задачи разделения смеси гауссовых распределений выглядит следующим образом. Задана выборка X^l случайных и независимых наблюдений из смеси $p(x)$, в которой описание i -го элемента есть вектор $x_i \in \mathbb{R}^n$. Принята модель, в которой каждая компонента смеси есть гауссиана с параметрами μ и Σ , и известно число компонентов смеси — K . Смесь показана в формуле (2).

$$p(x) = \sum_{n=1}^K \pi_k N(x|\mu_k, \Sigma_k). \quad (2)$$

Требуется оценить вектор параметров $\theta = (\pi_1, \dots, \pi_M, \mu_1, \dots, \mu_M, \Sigma_1, \dots, \Sigma_M)$, доставляющий максимум функции правдоподобия (3).

$$\ln p(X|\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k N(x_n|\mu_k, \Sigma_k) \right\} \quad (3)$$

Оптимальные параметры отыскиваются последовательно с помощью итерационного ЕМ-алгоритма. Основная идея — вводится вспомогательный вектор скрытых переменных. Это позволяет свести сложную оптимизационную задачу к последовательности итераций по пересчету коэффициентов (скрытых переменных по текущему приближению вектора параметров — Е-шаг) и максимизации правдоподобия (с целью найти следующее приближение вектора — М-шаг).

В начале работы алгоритма задаются параметры начального приближения θ_0 . Далее итеративно выполняется следующая пара процедур:

Е-шаг: используя текущее значение вектора параметров θ , вычисляется значение вектора скрытых переменных γ по формуле (4).

$$\gamma_{nk} = \frac{\pi_k N(x_n|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_n|\mu_j, \Sigma_j)} \quad (4)$$

М-шаг: переоценка вектора параметров по формулам (5), используя текущее значение вектора скрытых переменных.

$$\mu_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} x_n, \quad (5a)$$

$$\Sigma_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} (x_n - \mu_k^{new})(x_n - \mu_k^{new})^T, \quad (5b)$$

$$\pi_k^{new} = \frac{N_k}{N}, \quad (5b)$$

$$N_k = \sum_{n=1}^N \gamma_{nk}, \quad (5r)$$

Процедура останавливается после того, как норма разности векторов скрытых переменных на каждой итерации не будет превышать заданную константу Δ . Условие останова показано в (6).

$$\delta_{max} = \max \{ \delta_{max}, |\gamma_{nk} - \gamma_{nk}^0| \} \leq \Delta \quad (6)$$

Блок-схема алгоритма приведена в приложении А.

Для поиска аномалий могут быть использованы различные варианты моделей гауссовых смесей, например, модели для одного датчика системы (одномерный случай), либо для нескольких датчиков с учётом корреляции между ними (многомерный случай).

Оценка метода в применении к контролю и диагностике КА дана в [9] и [24].

Преимущества метода:

- возможность построения независимой модели для каждого датчика, что обеспечивает более точную диагностику;
- модель можно представить в графической форме.

Недостатки:

- строгие требования к исходным данным: если выборка не подчиняется нормальному распределению, то использование данного метода невозможно;
- метод не работает с выборками, имеющими коррелированные параметры;
- необходимость вручную задавать число кластеров, которое весьма трудно поддаётся определению в многомерных случаях и при больших объёмах данных [24].

1.2.4 DBN (Dynamic Bayesian Network)

Dynamic Bayesian Network, или динамическая байесовская сеть, является графической вероятностной моделью, представляющей собой множество переменных и их вероятностных зависимостей. Данный метод использует в своей работе формулу Байеса (7).

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}, \quad (7)$$

где $P(A)$ — априорная вероятность гипотезы A ;

$P(A|B)$ — вероятность гипотезы A при наступлении события B (апостериорная вероятность);

$P(B|A)$ — вероятность наступления события B при истинности гипотезы A ;

$P(B)$ — полная вероятность наступления события B .

Формула Байеса позволяет «переставить причину и следствие»: по известному факту события вычислить вероятность того, что оно было вызвано данной причиной. События, отражающие действие «причин», в данном случае называют *гипотезами*, так как они — предполагаемые события, повлекшие данное. Безусловную вероятность справедливости гипотезы называют *априорной* (насколько вероятна причина вообще), а условную — с учетом факта произошедшего события — *апостериорной* (насколько вероятна причина оказалась с учетом данных о событии).

Формально байесовская сеть — это направленный ациклический граф, каждой вершине которого соответствует случайная переменная, а дуги графа кодируют отношения условной независимости между этими переменными. Вершины могут представлять переменные любых типов, быть взвешенными параметрами, скрытыми переменными или гипотезами. Если переменные байесовской сети являются дискретными случайными величинами, то такая сеть называется дискретной байесовской сетью. Байесовские сети, которые моделируют последовательности переменных, называют *динамическими байесовскими сетями* [25].

Если дуга выходит из вершины A в вершину B , то A называют родителем B , а B называют потомком A . Если из вершины A существует ориентированный путь в другую вершину B , то B называется потомком A , а A называется предком B . Множество вершин-родителей вершины V_i обозначим как $parents(V_i) = PA_i$.

Направленный ациклический граф G называется байесовской сетью для вероятностного распределения $P(v)$, заданного над множеством случайных переменных V , если каждой вершине графа поставлена в соответствие случайная переменная из V , а дуги в графе удовлетворяют условию (марковское условие): любая переменная V_i из V должна быть условно независима от всех вершин, не являющихся ее потомками, если

заданы (получили означивание, обусловлены) все ее прямые родители PA_i в графе G , то есть выполняется выражение (8).

$$\forall V_i \in V : P(v_i|pa_i, s) = P(v_i|pa_i), \quad (8)$$

где v_i — значение V_i ;

S — множество всех вершин, не являющихся потомками V_i ;

s — конфигурация S ;

pa_i — конфигурация PA_i .

Тогда полное совместное распределение значений в вершинах можно удобно записать в виде декомпозиции (произведения) локальных распределений (9).

$$P(V_1, \dots, V_n) = \prod_{i=1}^n P(V_i|parents(V_i)) \quad (9)$$

Если у вершины V_i нет предков, то её локальное распределение вероятностей называют *безусловным*, иначе *условным*. Если вершина — случайная переменная получила означивание (например, в результате наблюдения), то такое означивание называют *свидетельством*. Если значение переменной было установлено извне (а не наблюдалось), то такое означивание называется *вмешательством* или *интервенцией* [25].

Условная независимость в байесовской сети представлена графическим свойством *d-разделённости*. Пусть X, Y, Z — непересекающиеся подмножества вершин в ациклическом ориентированном графе G . Говорят, что множество вершин Z *d-разделяет* X и Y тогда и только тогда, когда Z блокирует все пути из любой вершины, принадлежащей X , в любую вершину, принадлежащую Y . Под путём понимается последовательность следующих друг за другом рёбер (любого направления) в графе.

В соответствии с теоремой о *d-разделённости* для ациклично ориентированного графа G если вершины *d-разделены*, то они условно независимы; и если вершины условно-независимы во всех вероятностных распределениях, совместимых с графом G , то они *d-разделены* [25].

Для динамических байесовских сетей существуют две возможных стратегии для поиска аномалий [26]: байесовский доверительный интервал (Bayesian Credible Interval, BCI) и максимальная апостериорная оценка измерений (maximum a posteriori measurement status, MAP-ms).

1.2.4.1 Байесовский доверительный интервал (BCI)

Данная стратегия использует модель сети, представленную на рисунке 3. Вектор X представляет скрытые непрерывные переменные, вектор M — наблюдаемые непрерывные переменные. Нижние индексы обозначают моменты времени.




Рисунок 3 — Графическая модель сети для байесовского интервала правдоподобия (BCI)

Такая байесовская сеть отслеживает многомерные распределения линейных гауссовых переменных состояния и их наблюдаемые аналоги, которые измеряются с помощью датчиков. Скрытые переменные полагаются Марковскими процессами первого порядка, т.е. значение переменной в момент времени t зависит только от состояния в момент времени $t - 1$. Апостериорные вероятности скрытых и наблюдаемых переменных получаются с помощью фильтра Калмана, как только поступают новые измерения с датчиков. Данные вероятности используются для построения байесовского доверительного интервала $p\%$. Апостериорная вероятность p отражает тот факт, что наблюдаемая переменная находится внутри интервала. Таким образом, любое измерение, попадающее за пределы доверительного интервала $p\%$, может быть классифицировано как аномалия [26]. Параметры сети (распределения вероятностей $P(X_0)$, $P(X_t|X_{t-1})$, $P(M_t|X_t)$) могут быть получены из исходной выборки с помощью ЕМ-алгоритма [23].

1.2.4.2 Максимальная апостериорная оценка измерений (MAP-ms)

В стратегии MAP-ms используется более сложная модель сети, показанная на рисунке 4. Векторы X и Z представляют непрерывные и дискретные скрытые переменные, а вектор M — наблюдаемые непрерывные переменные. Нижние индексы обозначают моменты времени.




Рисунок 4 — Графическая модель сети для максимального апостериорного статуса измерений (MAP-ms)

Данная модель отслеживает многомерные многомерные распределения линейных гауссовых переменных состояния и их наблюдаемые аналоги, которые измеряются с помощью датчиков, как и вероятности скрытых дискретных переменных, показывающих статус каждого измерения (например, номинальный/аномальный). К примеру, если есть две измеряемых переменных состояния, то дискретная переменная статуса измерения будет иметь четыре возможных значения: (номинальный, номинальный), (аномальный, номинальный), (номинальный, аномальный) и (аномальный, аномальный). Апостериорные вероятности скрытых и наблюдаемых переменных получаются с помощью фильтра частиц Рао-Блэквелла, как только поступают новые измерения с датчиков. Максимальная апостериорная оценка измерения (например, наиболее вероятное значение, полученное из апостериорной вероятности) скрытой переменной состояния, показывающей статус измерения, может быть использована для классификации измерения как номинального или аномального.

MAP-ms для работы требует, во-первых, параметры байесовской сети, описывающие изменение во времени линейных гауссовых переменных состояния для каждого значения дискретного статуса измерения, и, во-вторых, параметры, описывающие изменение во времени дискретных переменных. Кроме того, необходимо вручную задать вероятности для дискретных переменных ($P(Z_0)$, $P(Z_t|Z_{t-1})$), опираясь на знание предметной области. Для случая, когда аномалий в исходной выборке нет, параметры сети совпадают с сетью для стратегии BCI, описанной в пункте 1.2.4.1. Если же од-

но или несколько измерений являются аномальными, параметры сети могут довольно сильно отличаться. [26]

Основные преимущества динамических байесовских сетей в применении к обнаружению аномалий:

- способность работать в режиме реального времени [26];
- возможность графически представить модель системы.

Недостатки:

- крайне высокая сложность метода;
- низкая эффективность на реальных данных [9].

1.2.5 One-Class SVM (Support Vector Machine)

Метод опорных векторов — набор схожих алгоритмов обучения с учителем, использующихся для задач классификации и регрессионного анализа. One-Class SVM, или одноклассовый метод опорных векторов, представляет собой специальный вариант данного семейства для поиска аномалий, позволяющий использовать его в задачах обучения без учителя. В случае, если новое измерение принадлежит классу, оно считается номинальным (система работает в номинальном режиме); если же нет, то это измерение является аномалией. Особым свойством метода опорных векторов является непрерывное уменьшение эмпирической ошибки классификации и увеличение зазора, поэтому метод также известен как *метод классификатора с максимальным зазором*.

Основная идея метода — перевод исходных векторов из низкой размерности, где они могут быть линейно неразделимы, в пространство более высокой размерности (вплоть до бесконечной) и поиск разделяющей гиперплоскости с максимальным зазором в этом пространстве. Две параллельных гиперплоскости строятся по обеим сторонам гиперплоскости, разделяющей классы. Разделяющей гиперплоскостью будет гиперплоскость, максимизирующая расстояние до двух параллельных гиперплоскостей. Алгоритм работает в предположении, что чем больше разница или расстояние между этими параллельными гиперплоскостями, тем меньше будет средняя ошибка классификатора [27].

Формальное описание задачи для случая с одним классом выглядит следующим образом: дана выборка $\Omega = \{x_1, x_2, \dots, x_n\}$, $x_i \in \mathbb{R}^m$, где x_i — точка в m -мерном пространстве, а $y_i \in \{0, 1\}$ определяет принадлежность точки классу. Строится раз-

деляющая гиперплоскость, которая имеет вид (10a), и гиперплоскость, параллельная ей (10б).

$$w^T x + b = 0; \quad (10a)$$

$$w^T x + b = 1, \quad (10б)$$

где $w \in \mathbb{F}$ — перпендикуляр к разделяющей гиперплоскости;

$b \in \mathbb{R}$ — расстояние по модулю от гиперплоскости до начала координат.

Если обучающая выборка линейно разделима, то возможно выбрать гиперплоскости таким образом, чтобы между ними не лежала ни одна точка обучающей выборки, и затем максимизировать расстояние между гиперплоскостями. Ширину полосы между ними легко найти из соображений геометрии, она равна $\frac{1}{\|w\|}$ [28], таким образом, задача сводится к минимизации $\|w\|$. Чтобы уберечь классификатор от переополнения зашумлёнными данными, вводятся ошибки ξ_i , позволяющие некоторым точкам лежать внутри зазора, и константа $C > 0$, определяющая соотношение между максимизацией зазора и количеством точек внутри него (и, соответственно, ошибкой обучения). Целевая функция с учётом этих условий имеет вид (11) [29].

$$\begin{aligned} \min_{w, b, \xi_i} \frac{\|w\|^2}{2} + C \sum_{i=1}^n \xi_i, \\ y_i(w^T \phi(x_i) + b) \geq 1 - \xi_i \quad \text{для всех } i = 1, \dots, n, \\ \xi_i \geq 0 \quad \text{для всех } i = 1, \dots, n. \end{aligned} \quad (11)$$

Оригинальная версия метода опорных векторов относится к семейству алгоритмов линейной классификации, что не подходит для задачи поиска аномалий в реальных многомерных данных. Существует способ создания нелинейного классификатора, в основе которого лежит переход от скалярных произведений к произвольным ядрам, так называемый *kernel trick*, позволяющий строить нелинейные разделители. Результирующий алгоритм крайне похож на алгоритм линейной классификации, с той лишь разницей, что каждое скалярное произведение в приведённых выше формулах заменяется нелинейной функцией ядра (скалярным произведением в пространстве с большей размерностью). В этом пространстве уже может существовать оптимальная разделяющая гиперплоскость. Так как размерность получаемого пространства может быть больше

размерности исходного, то преобразование, сопоставляющее скалярные произведения, будет нелинейным, а значит функция, соответствующая в исходном пространстве оптимальной разделяющей гиперплоскости, будет также нелинейной [27]. Общий вид ядра показан в формуле (12).

$$K(x, x_i) = \phi(x)^T \phi(x_i) \quad (12)$$

Наиболее распространённые ядра [27]: полиномиальное однородное (13а), полиномиальное неоднородное (13б), радиальная базисная функция (13в), радиальная базисная функция Гаусса (13г).

$$K(x, x_i) = (x \cdot x_i)^d; \quad (13а)$$

$$K(x, x_i) = (x \cdot x_i + 1)^d; \quad (13б)$$

$$K(x, x_i) = \exp(-\gamma \|x - x_i\|^2), \gamma > 0; \quad (13в)$$

$$K(x, x_i) = \exp(-\frac{\|x - x_i\|^2}{2\sigma^2}). \quad (13г)$$

Преимущества метода:

- метод сводится к решению задачи квадратичного программирования, которая всегда имеет единственное решение;
- даёт численную оценку аномальности (расстояние от точки до гиперплоскости) [9].

Недостатки:

- метод неустойчив по отношению к шуму в исходных данных. Если обучающая выборка содержит шумовые выбросы, они будут существенным образом учтены при построении разделяющей гиперплоскости;
- необходимо вручную подбирать функцию ядра, исходя из знаний о предметной области и природе исходных данных;
- в общем случае, когда линейная разделимость не гарантируется, приходится подбирать управляющий параметр алгоритма C [28];
- в случае значительных изменений в режиме работы системы не способен обнаруживать аномалии [9].

1.2.6 Inductive Monitoring System (IMS)

IMS автоматически строит базу знаний для последующего мониторинга состояния системы на основе номинальных данных, собранных непосредственно во время работы системы либо её симуляций. IMS использует машинное обучение и методы интеллектуального анализа данных для описания типичного для системы поведения путём извлечения из исходных данных основных классов. В частности, IMS использует кластеризацию для группировки постоянно встречающихся последовательностей в обучающей выборке. Кластеризация — семейство алгоритмов, относящееся к обучению без учителя, упорядочивающих объекты в сравнительно однородные группы (*кластеры*). Идея метода IMS проистекает из двух алгоритмов кластеризации: алгоритма К-средних (K-means) [30] и DBSCAN [31] (кластеризация на основе плотности групп точек). Метод разработан Дэвидом Иверсоном (NASA Ames Research Center) и описан им в [8].

Базовой структурой данных для этого метода является вектор параметров системы. Пример подобного вектора приведён в таблице 1. Каждый вектор содержит упорядоченный набор параметров, полученный системой мониторинга в процессе сбора телеметрии. Он также может содержать производные от измерений параметры. Векторы параметров системы представляют собой точки в N -мерном пространстве, которые IMS группирует в кластеры. Значения вектора могут быть получены подсистемой сбора данных как одновременно, либо быть собранными в вектор из нескольких измерений в течение некоторого периода времени. Размер и конкретные параметры вектора определяются вручную в соответствии с поставленной задачей мониторинга.

Таблица 1 — Пример вектора данных IMS

Давление А	Позиция клапана 1	Давление В	Позиция клапана 2	Температура 1	Температура 2
2857.2	86.4%	1218.4	96.2%	49.8	37.6

IMS обрабатывает обучающую выборку, форматируя исходные данные в соответствии с заданной структурой вектора параметров, и строит базу знаний из кластеров. Пример подобного кластера приведён в таблице 2. Каждый кластер определяет диапазон допустимых значений всех переменных для входного вектора данных. Век-

тор верхней границы и вектор нижней границы в кластере могут быть представлены, как углы минимального ограничивающего гиперкуба в N -мерном пространстве. Точки, попадающие внутрь этого гиперкуба либо в его окрестность, классифицируются алгоритмом как относящиеся к номинальному режиму работы системы, так как гиперкуб определяется исходя из номинальных данных. Данный подход схож с интервальной диагностикой, когда строится математическая модель системы, и определяются допустимые диапазоны изменения каждой переменной, но не требует знаний о характере и устройстве системы.

Таблица 2 — Пример кластера IMS

	Давление А	Позиция клапана 1	Давление В	Позиция клапана 2	Температура 1	Температура 2
Верхняя граница	2857.2	86.4%	1218.4	96.2%	49.8	37.6
Нижняя граница	2857.2	86.4%	1218.4	96.2%	49.8	37.6

IMS начинает процесс обучения с пустой базы кластеров. Метод считывает элементы обучающей выборки и формирует из них векторы. Первый вектор добавляется в базу, как исходный кластер. Каждый последующий вектор сравнивается с содержимым базы кластеров с тем, чтобы найти ближайший к этому вектору кластер. Для определения расстояния между вектором и кластером могут быть использованы различные метрики, например, Евклидово расстояние. Для того, чтобы найти расстояние от вектора до кластера, необходимо выбрать точку в кластере, до которой оно будет измерено. Одним из вариантов, основанным на алгоритме К-средних [30], является выбор центроида кластера, который рассчитывается как среднее между нижней и верхней границами. Для каждого нового вектора из обучающей выборки IMS находит в базе ближайший к нему кластер. Далее определяется, попадает ли вектор внутрь ограничивающего гиперкуба данного кластера или в его окрестность. Как и в кластеризации на основе плотности точек [31], вводится пороговое значение ε , заданное пользователем, которое определяет максимальное допустимое расстояние между вектором и кластером. На основе этого расстояния алгоритм определяет, стоит ли добавлять вектор в кластер. Если

вектор достаточно близок (расстояние меньше или равно ε), границы кластера раздвигаются, чтобы вместить его. Если же расстояние превышает ε , создаётся новый кластер и добавляется в базу. Процесс обучения повторяется до тех пор, пока не будет обработана вся обучающая выборка. Малое значение ε приводит к созданию небольших по размеру кластеров, что обеспечивает более точный контроль, но значительно увеличивает размер базы знаний, делая невозможным мониторинг системы в реальном времени. Значение ε может быть подобрано таким образом, чтобы обеспечить баланс между скоростью работы и точностью контроля.

Блок-схема процесса обучения приведена в приложении Б.

Результатом обработки IMS обучающей выборки является модель системы в виде базы кластеров, характеризующая работу системы в номинальных режимах, отображённых в исходных данных. В дополнение к этому, каждый кластер определяет ограничения на значения каждого из параметров в векторе.

Для использования получившейся базы кластеров для мониторинга состояния системы IMS формирует векторы из приходящих данных и запрашивает базу на предмет ближайшего к каждому входному вектору кластера. Наиболее быстрый способ проверки требует, чтобы все векторы находились внутри по крайней мере одного из кластеров внутри базы (значения всех параметров должны находиться внутри диапазонов, определённых границами кластера). Такой способ устраняет необходимость вычисления расстояний. Более информативная техника мониторинга находит ближайший к входному вектору кластер и показывает пользователю расстояние между ними. Это даёт оператору представление, насколько поведение системы отклоняется от нормального, представленного в обучающей выборке. Метод может учитывать неполноту обучающей выборки и неточности измерений путём задания порогового значения ε .

Блок-схема процесса мониторинга приведена в приложении В.

Преимущества метода:

- не требует больших вычислительных ресурсов, способен работать в реальном времени;
- предоставляет оператору численную характеристику аномальности вектора измерений;
- не имеет ограничений на закон распределения входных данных;
- не требует никаких знаний о предметной области, природе системы, её внут-

реннем устройстве, характеристиках входных данных, что обеспечивает универсальность и возможность применения к широкому спектру технических систем.

Недостатки:

- метод неустойчив по отношению к шуму и аномалиям в обучающей выборке;
- вектор входных данных может содержать только непрерывные переменные;
- стандартный вариант метода рассчитывает расстояние до центра кластера, что снижает точность мониторинга.

1.3 Разработка метода мониторинга состояния ЛА на основе методов интеллектуального анализа данных

Все описанные выше методы имеют свои недостатки при их применении для диагностики сложных технических систем. Сравнение методов по критериям, указанным в разделе 1.1, приведено в таблице 3.

По результатам сравнения наиболее подходящим является метод IMS, описанный в подразделе 1.2.6. Так как он не удовлетворяет всем требованиям, указанным в разделе 1.1, необходимо создать на его основе метод, устойчивый к аномалиям в обучающей выборке, обеспечивающий возможность классификации аномалий и работающий не только с непрерывными, но и с дискретными параметрами.

1.3.1 Формальная постановка задачи мониторинга системы

Введём следующие обозначения:

M — дискретно-непрерывное пространство, имеющее p непрерывных и q дискретных измерений;

$R = \{R_1, R_2, \dots, R_n\} \in M$ — множество режимов работы системы;

$T = \{x_1, x_2, \dots, x_m\} \in M$ — обучающая выборка;

$x = \{a_1, a_2, \dots, a_p, b_1, b_2, \dots, b_q\} \in M, a_i \in \mathbb{R}, b_i \in \mathbb{N}$ — элемент обучающей выборки;

$\theta = \{\tilde{a}_1, \tilde{a}_2, \dots, \tilde{a}_p, \tilde{b}_1, \tilde{b}_2, \dots, \tilde{b}_q\} \in M, \tilde{a}_i \in \mathbb{R}, \tilde{b}_i \in \mathbb{N}$ — входной вектор;

$\Omega = \{\omega_1, \omega_2, \dots, \omega_{p+q}\}$ — вектор весов.

Необходимо отметить, что некоторые значения в векторах могут отсутствовать.

Таблица 3 — Сравнение методов выявления аномалий без учителя

Критерий \ Метод	Orca	GritBot	GMM	DBN	SVM	IMS
Построение модели системы без априорных данных о предметной области, назначении системы, её составе, конструкции	+	+	\pm	+	—	+
Классификация аномалий	—	—	—	+	—	—
Численная характеристика аномалии	+	—	—	—	+	+
Обработка больших выборок за конечное время	\pm	—	\pm	+	+	+
Работа с дискретными параметрами	+	+	—	\pm	—	—
Отсутствие ограничений на закон распределения входных данных	+	+	—	\pm	+	+
Устойчивость к аномалиям в обучающей выборке	+	+	—	—	—	—
Устойчивость к отсутствию значений параметров во входных данных	+	+	—	—	—	+
Работа в режиме реального времени	—	—	+	+	+	+

Даны n обучающих выборок $T_1 \in R_1, T_2 \in R_2, \dots, T_n \in R_n$ различной длины, содержащие m_i элементов каждая, где i — номер режима работы системы. Дан вектор Ω , содержащий веса, соответствующие важности каждого параметра системы. Дан входной вектор θ .

Необходимо определить, принадлежит ли θ к R ; если $\theta \in R$, то определить, в каком именно подмножестве $R_i \in R$ находится θ . Если же $\theta \notin R$, найти численную меру $\lambda \in \mathbb{R}_{\geq 0}$, показывающую отклонение θ от R .

1.3.2 Описание метода

Предложенный ниже метод относится к методам, основанным на измерении расстояний между точками (distance-based). Поэтому для работы метода необходимо определить взвешенную метрику $d(x, y, \Omega)$ на пространстве M . В качестве такой метрики может выступать комбинация Евклидова расстояния (14а) для непрерывных и функции отличия (14б) для дискретных переменных. Подобная метрика, определённая на пространстве M , показана в формуле (15). В случае отсутствия значения прибавляется только вес данного параметра.

$$D_E(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (14a)$$

$$D_{diff}(x, y) = \begin{cases} 0, & x = y, \\ 1, & x \neq y \end{cases} \quad (14б)$$

$$d(x, y, \Omega) = \sqrt{\sum_{i=1}^p \left[\omega_i \left(a_i^{(x)} - a_i^{(y)} \right)^2 \right]} + \sum_{j=1}^q \left[\begin{cases} 0, & b_j^{(x)} = b_j^{(y)}, \\ \omega_j, & b_j^{(x)} \neq b_j^{(y)} \end{cases} \right] \quad (15)$$

Блок-схема процесса обучения метода представлена в приложении Г.

Обучение метода проходит в два этапа: подготовка данных и формирование базы режимов.

Пример единицы входных данных для метода представлен в таблице 4.

Таблица 4 — Пример единицы входных данных разрабатываемого метода

Давление А	Состояние клапана 1	Давление В	Состояние клапана 2	Температура 1	Температура 2
2857.2	Закрыт	1218.4	Открыт	49.8	37.6

1.3.2.1 Подготовка данных

Формат входных данных, показанный в таблице 4, может не соответствовать формату, описанному в подразделе 1.3.1. Для этого необходимо сгруппировать пара-

метры по своей природе (отдельно непрерывные и отдельно дискретные). Для каждого дискретного параметра составляется список возможных значений, в соответствие которым ставятся натуральные числа.

Так как элементы в векторах могут иметь различный масштаб, для корректного определения расстояния между двумя точками непрерывные значения векторов сначала необходимо нормализовать. Для этого может применяться как минимаксная нормализация (16а), так и нормализация с помощью стандартного отклонения (16б). Метод сохраняет характеристики, используемые при нормализации обучающих выборок (минимум, среднее значение и т.д.), для масштабирования входного вектора на стадии мониторинга.

$$\hat{x} = \frac{x - \min(X)}{\max(X) - \min(X)}, x \in X \quad (16a)$$

$$\hat{x} = \frac{x - \bar{x}}{\sigma_x}, \quad (16b)$$

где \bar{x} — среднее значение;

σ_x — стандартное отклонение.

Зачастую в обучающих выборках могут содержаться аномальные элементы (сбой в работе датчика, искажения в канале связи и т.д.). Для того, чтобы метод мог корректно обучаться, необходимо их исключить. Для этого на каждой выборке используется алгоритм Orca, описанный в подразделе 1.2.1. В качестве количества аномалий, которые необходимо найти, ему задаётся число элементов в выборке. С учётом этой особенности на выходе данный алгоритм выдаёт численную меру (степень) аномальности для каждого вектора. Далее применяется фильтр, который на основе этой численной меры для каждого вектора определяет, является ли вектор аномальным. Для этого могут использоваться как статистические (например, Гауссовый фильтр, считающий аномальными все векторы, численная мера для которых не укладывается в диапазон $[0, 3\sigma]$), так и пороговые фильтры (считающие аномальными векторы, численная мера которых выше определённой величины δ). Выбранные фильтром аномалии удаляются из выборки.

Результатом данного этапа являются нормализованные выборки $\hat{T}_i \in \hat{T}$, $i \in [1, n]$, не содержащие аномалий. Пример элемента такой выборки представлен в таблице 5.

Таблица 5 — Пример подготовленной единицы входных данных разрабатываемого метода

a_1	a_2	a_3	a_4	b_1	b_2
0.91	0.38	0.85	0.64	0	1

1.3.2.2 Формирование базы режимов

На данном этапе производится создание отдельной базы кластеров для каждого режима работы системы $R_i, i \in [1, n]$. Блок-схема процесса представлена в приложении Д.

Каждый кластер определяет диапазон допустимых значений для непрерывных переменных (a_1, a_2, \dots, a_p) и список допустимых значений для каждой дискретной переменной из (b_1, b_2, \dots, b_q) . Пример такого кластера представлен в таблице . Вектор верхней границы и вектор нижней границы в кластере могут быть представлены, как углы минимального ограничивающего прямоугольного параллелепипеда в p -мерном пространстве (p — число непрерывных переменных в векторе).

Таблица 6 — Пример кластера разрабатываемого метода

	a_1	a_2	a_3	a_4	b_1	b_2
Верхняя граница	0.91	0.38	0.85	0.64	—	—
Нижняя граница	0.45	0.45	0.55	0.14	—	—
Допустимые значения	—	—	—	—	0, 1	1

Метод последовательно обрабатывает все векторы из выборки $T_i \in R_i$. Процесс начинается с пустой базой кластеров. Первым вектором инициализируется начальный кластер (нижняя и верхняя граница этого кластера считаются равными вектору, в списки допустимых значений дискретных переменных добавляются значения дискретных переменных вектора). Каждый последующий вектор сравнивается со всеми кластерами в базе. Если вектор полностью находится в границах кластера, то метод переходит к следующему вектору в обучающей выборке. Если вектор не попал ни в один кластер, то измеряется расстояние $d_c(x, c, \Omega)$ между вектором и всеми кластерами в базе с

целью нахождения наиболее близкого кластера. Вводится пороговое значение ε , заданное пользователем, которое определяет максимальное допустимое расстояние между вектором и кластером (размер окрестности кластера). Если $d_c(x, c, \Omega) \leq \varepsilon$, то вектор находится в окрестности кластера и может быть включён в него. При этом границы кластера расширяются, чтобы включить в себя вектор, а в списки допустимых значений дискретных переменных добавляются соответствующие значения элементов вектора. Если же $d_c(x, c, \Omega) > \varepsilon$, то формируется новый кластер, инициализирующийся этим вектором, и добавляется в базу. Процесс обучения повторяется до тех пор, пока не будет обработана вся обучающая выборка. Малое значение ε приводит к созданию небольших по размеру кластеров, что обеспечивает более точный контроль, но значительно увеличивает размер базы знаний, делая невозможным мониторинг системы в реальном времени. Значение ε может быть подобрано таким образом, чтобы обеспечить баланс между скоростью работы и точностью контроля.

Функция расстояния $d_c(x, c, \Omega)$ может быть определена различными способами, зависящими от точки в кластере, до которой измеряется расстояние. В отличие от метода IMS, описанного в подразделе 1.2.6, использующего расстояние до центра кластера (рисунок 5а), предлагается использовать расстояние до ближайшей точки кластера (рисунок 5б), обеспечивающее более точную оценку удалённости вектора от границ кластера.




Рисунок 5 — Виды расстояний от вектора до кластера

Результатом работы данного этапа является модель системы, состоящая из ре-

жимов, каждый из которых содержит базу кластеров. Структура модели показана на рисунке 6.




Рисунок 6 — Структура модели системы для разрабатываемого метода

1.3.2.3 Мониторинг состояния системы

Для использования получившейся модели системы для мониторинга текущего состояния требуется получить из пришедшего вектора измерений входной вектор θ в формате, описанном в подразделе 1.3.1, и нормализовать его. Для этого над вектором измерений производятся операции, описанные в пункте 1.3.2.1. Нормализация производится с использованием характеристик, сохранённых на аналогичном этапе при подготовке данных обучающих выборок.

2 Расчет экономической эффективности системы

2.1 Введение

Для оценки экономической эффективности программно-аппаратного продукта требуется:

- определить целесообразность разработки;
- определить трудоёмкость и затраты на создание;
- определить показатели экономической эффективности разработки.

Результатом выполнения данной части является обоснование технической, экономической и научной значимости и целесообразности продукта в соответствии с [32]. Объектом технико-экономического анализа является программная система мониторинга состояния ЛА на основе методов интеллектуального анализа данных.

2.2 Определение целесообразности разработки

Для обоснования целесообразности разработки продукта необходимо:

- выбрать аналог (если таковой имеется);
- сформулировать перечень функциональных характеристик по предлагаемому варианту разработки продукта;
- определить конкретные уровни характеристик и их значимость;
- определить индекс технического уровня программного продукта.

Функционально-технические характеристики разрабатываемого программного продукта представлены в таблице 7.

Индекс технического уровня разрабатываемого программного продукта определяется по формуле (17):

$$J_{TY} = \sum_{i=1}^n \frac{\alpha_i}{\alpha_{i0}} \mu_i, \quad (17)$$

где α_i — уровень i -й функционально-технической характеристики проектируемого алгоритма;

α_{i0} — уровень i -й функционально-технической характеристики базового алгоритма;

Таблица 7 — Функционально-технические характеристики

Функциональные характеристики	Единица измерения	Величина функциональных характеристик		Значимость характеристик
		Аналог	Новый вариант	
Простота использования	По 10-бальной шкале	2	9	0.05
Быстродействие	По 10-бальной шкале	5	10	0.2
Открытость	По 10-бальной шкале	3	10	0.15
Точность вычислений	По 10-бальной шкале	8	8	0.2
Надёжность	По 10-бальной шкале	9	7	0.2

μ_i — значимость i -го параметра;

n — количество рассматриваемых параметров.

$$J_{TY} = \frac{9}{2} \cdot 0.05 + \frac{10}{5} \cdot 0.2 + \frac{10}{3} \cdot 0.15 + \frac{8}{8} \cdot 0.2 + \frac{7}{9} \cdot 0.2 = 1.48.$$

Значение показателя технического уровня разрабатываемого программного продукта превышает 1 и равно 1.48. Полученный результат является подтверждением целесообразности разработки продукта.

2.3 Определение трудоемкости и затрат на создание ПП

Основой для определения затрат на создание ПП является показатель трудоемкости работ. В таблице 8 представлена структура затрат труда на создание ПП.

Таблица 8 — Структура затрат труда на создание ПП

№ п/п	Наименование (стадии) этапа работ	Доля работ на стадии (этапе) в общем объёме работ, %
1	Анализ предметной области и изучение средств разработки	3
2	Изучение программируемой задачи	5
3	Определение входных и выходных данных	3
4	Анализ методов решения задачи	5
5	Составление структуры ПП	4
6	Технико-экономическое обоснование выбора вариантов решения задачи	5
7	Уточнение и доработка выбранного варианта решения	3
8	Создание ПП	35
9	Отладка ПП	22
10	Испытание и анализ работы ПП в реальных условиях	10
11	Составление технической документации	5
	ИТОГО	100

Затраты труда определяются по формуле (18).

$$t_{ПРТ} = t_O + t_{II} + t_A + t_K + t_{OT} + t_d \quad (18)$$

$B = 2$ — увеличение затрат труда на изучение и постановку задачи вследствие их сложности и новизны;

$K = 0.8$ — коэффициент квалификации разработчика;

$$Q = q \cdot K_c \cdot (1 + \sum^n K_k) = 500 \cdot 1.5 \cdot (1 + (0.2 + 0.1)) = 975.$$

$t_O = 40$ — затраты труда на подготовку описания задачи;

$$t_{II} = \frac{Q \cdot B}{75 \cdot K} = 32.5 \text{ — затраты труда на изучение и постановку задачи;}$$

$$t_A = \frac{Q}{20 \cdot K} = 60.94 \text{ — затраты труда на проектирование системы;}$$

$t_K = \frac{Q}{10 \cdot K} = 121.88$ — затраты труда на программирование;

$t_{OT} = \frac{Q}{5 \cdot K} = 243.75$ — затраты труда на отладку программы;

$t_D = \frac{1.75 \cdot Q}{15 \cdot K} = 142.19$ — затраты труда на подготовку документации.

Таким образом, $t_{ПРТ} = 40 + 32.5 + 60.94 + 121.88 + 243.75 + 142.19 = 641.26$.

2.4 Определение исполнителей

Исполнители указаны в таблице 9.

Таблица 9 — Исполнители

Категория исполнителей	Число исполнителей	Зарплата с учетом премии (руб./мес.)	Часовые тарифные ставки, руб.
Инженер-программист	1	60000	360

2.5 Расчет заработной платы исполнителей

Оплата труда персонала определяется на основе общей трудоёмкости создания ПП по формуле (19).

$$ЗП_{ПП} = \sum_{i=1}^k T_i \cdot \bar{\tau}_i, \quad (19)$$

где k — количество этапов;

T_i — трудоёмкость i -го этапа;

$\bar{\tau}_i$ — средняя дневная тарифная ставка оплаты i -го этапа.

Результаты приведены в таблице 10.

Таблица 10 — Заработная плата исполнителей

№ п/п	Наименование этапов и работ	Трудоёмкость стадии (чел.-ч.)	Часовая ставка (руб/ч)	Зарплата за работу (руб)
1	Анализ предметной области и изучение средств разработки	40	360	6000
2	Изучение программируемой задачи	32.5	360	11700
3	Определение входных и выходных данных			
4	Анализ методов решения задачи			
5	Составление структуры ПП	60.94	360	21938.40
6	Технико-экономическое обоснование выбора вариантов решения задачи			
7	Уточнение и доработка выбранного варианта решения			
8	Создание ПП	121.88	360	43876.80
9	Отладка ПП	243.75	360	87750
10	Испытание и анализ работы ПП в реальных условиях			
11	Составление технической документации	142.19	360	51188.40
	ИТОГО	641.26	—	230853.60

2.6 Социальные отчисления

Социальные отчисления основных исполнителей составляет 30.2% от $ЗП_{ПП}$.

$$З_{CO} = 230853.60 \cdot 0.302 = 69717.79 \text{ (руб.)}$$

2.7 Накладные расходы

Под накладными расходами понимаются расходы на электроэнергию в период первого полугодия эксплуатации системы. Они рассчитываются по формуле (20).

$$K_{ЭЭ} = N_{\text{раб.дн.}} \cdot \sum P \cdot N_{\text{часов}} \cdot N_{\text{лет}} \cdot C_{ЭЭ}, \quad (20)$$

где $N_{\text{раб.дн.}}$ — количество рабочих дней в году;

$\sum P$ — суммарная потребляемая в час мощность оборудования (компьютер используется в течение всего рабочего дня, а принтеры — в среднем в течение половины рабочего дня);

$N_{\text{часов}}$ — количество рабочих часов в день;

$N_{\text{лет}}$ — количество лет разработки или использования системы;

$C_{ЭЭ}$ — стоимость одного киловатт/часа электроэнергии.

Таким образом, $K_{ЭЭ} = 224 \cdot 4.3 \cdot 8 \cdot 0.5 \cdot 4.5 = 17337.6 \text{ (руб.)}$

2.8 Прочие расходы

Прочие прямые расходы — это расходы на использование машинного времени. Система будет разрабатываться в течение 90 дней в среднем по 8 часов ежедневно. При стоимости машинного времени 13 руб./час, получаем:

$$З_{\text{м.в.}} = 90 \cdot 8 \cdot 13 = 9360.00 \text{ (руб.)}$$

Сведём все расходы на создание и эксплуатацию системы в таблицу 11.

2.9 Расчет стоимости

Цена программного продукта определяется исходя из принципа обеспечения безубыточности деятельности организации, получения прибыли, позволяющей выплачивать обязательные платежи в бюджет и инвестировать расширение деятельности.

Цена первоначальной продажи определяется по формуле (21).

$$Ц_{\text{НТПр}}^n = З_{\text{НТПр}} + \frac{ЗП_{\text{ПП}} \cdot \rho_{ЗП}}{100}, \quad (21)$$

Таблица 11 — Сводная таблица расходов

№ п/п	Виды расходов	Расходы, руб.	Удельный вес, %
1	Заработная плата разработчиков	230853.60	70.54
2	Социальные отчисления	69717.79	21.3
3	Накладные расходы	17337.6	5.3
4	Прочие расходы	9360	2.86
	ИТОГО	327268.99	100

где $З_{НТПр}$ — текущие затраты на создание, определяющиеся по формуле (22):

$$З_{НТПр} = З_{П_{mn}} + З_{М.В.}; \quad (22)$$

$З_{П_{mn}}$ — оплата труда основного персонала в общих текущих затратах на создание программного продукта;

$\rho_{ЗП}$ — уровень рентабельности (прибыли по отношению к оплате труда персонала), обеспечивающий безубыточность деятельности ($\rho_{ЗП} = 200\%$).

Таким образом,

$$З_{НТПр} = 230853.60 + 9360 = 240213.60 \text{ руб.};$$

$$Ц_{НТПр}^n = 240213.60 + \frac{230853.60 \cdot 200}{100} = 701920.80 \text{ руб.}$$

2.10 Оценка экономической эффективности

Так как данная дипломная работа связана с разработкой алгоритмов и программ, то $\mathcal{Э}_{НТП}$ определяется по формуле (23).

$$\mathcal{Э}_{НТП} = \sum_{i=1}^n \Delta T_{mi} \cdot C_{BT}, \quad (23)$$

где ΔT_{mi} — экономия машинного времени, ч.;

C_{BT} — стоимость одного машинного часа, руб.;

$n = 3000$ — количество задач, решаемых в год.

$$\mathcal{E}_{НТП} = 3000 \cdot 8 \cdot 50 = 1200000 \text{ (руб.)}$$

Уровень экономической эффективности ($E_{ПП}$) и срок окупаемости затрат на создание алгоритмов и ПП (T_{OK}) определяется по формулам (24) и (25).

$$E_{ПП} = \frac{\mathcal{E}_{НТП}}{C_{НТПр}} \quad (24)$$

$$T_{OK} = \frac{1}{E_{ПП}} \quad (25)$$

Таким образом,

$$E_{ПП} = \frac{1200000}{701920.80} = 1.71;$$

$$T_{OK} = \frac{1}{1.71} = 0.59 \text{ (года)}.$$

Так как уровень экономической эффективности составляет 1.71, то можно сделать вывод о том, что разработанный ПП выгоден с экономической точки зрения.

2.11 Календарное планирование

Календарный план работ представлен в таблице 12.

Таблица 12 — Календарный план работ

№ п/п	Наименование этапов (стадий, видов работ)	Удельный вес, %	Трудоемкость этапа, чел.-ч.	Кол-во ис- полнителей	Длительность этапа
1	Анализ предметной области и изучение средств разработки	6.24	40	1	6
2	Изучение программируемой задачи	2.31	14.8	1	1
3	Определение входных и выходных данных	1.21	7.76	1	5

Продолжение таблицы 12

№ п/п	Наименование этапов (стадий, видов работ)	Удельный вес, %	Трудоемкость этапа, чел.-ч.	Кол-во ис- полнителей	Длительность этапа
4	Анализ методов решения задачи	1.55	9.94	1	14
5	Составление структуры ПП	3.7	23.74	1	6
6	Технико- экономическое обоснование выбора вариантов решения задачи	4	25.66	1	6
7	Уточнение и доработка выбранного варианта решения	1.8	11.54	1	4
8	Составление ПП	19.01	121.88	1	39
9	Отладка ПП	22	141.08	1	16
10	Испытание и анализ работы ПП в реальных условиях	16.01	102.67	1	13
11	Составление технической документации	22.17	142.19	1	8
	ИТОГО	100	641.26	1	118

Производственный цикл каждого этапа определяется по формуле (26).

$$T_{uj} = \frac{T_j}{t_{pd} \cdot q_j}, \quad (26)$$

где T_j — трудоёмкость j -ой стадии (j -го этапа), чел.-час.;

t_{pd} — продолжительность рабочего дня, час.;

q_j — количество работников, одновременно участвующих в выполнении работ на j -ой стадии (j -м этапе), чел.

На основании данных таблицы 12 построен сетевой график (рисунок 7).




Рисунок 7 — Календарный план-график работ

2.12 Выводы

В экономической части дипломной работы получены следующие значения экономических показателей:

- Технический уровень $J_{TY} = 1.48$. Значение этого показателя должно быть больше 1. Полученное значение говорит о высоком техническом уровне разрабатываемого изделия.

– Уровень экономической эффективности $E_{III} = 1.71$.

На основании показателей экономической эффективности считаем разрабатываемую систему экономически эффективной и внедрение в производство целесообразным.

3 Охрана труда и окружающей среды

3.1 Анализ условий труда

3.1.1 Обеспечение условий труда в отделе разработки программного обеспечения

Дипломная работа посвящена разработке системы мониторинга состояния ЛА на основе алгоритмов интеллектуального анализа данных. Разработка производится на персональном компьютере и предполагает длительное пребывание за ним инженера.

Применение персонального компьютера освобождает человека от непроизводительной работы, связанной с обработкой информации, изменяет характер его труда. Однако при этом увеличивается доля умственного и нервно-напряженного труда, возрастает психоэмоциональная нагрузка. При значительной трудовой нагрузке, нерациональной организации работы и неблагоприятных факторах производственной среды быстро снижается работоспособность операторов, уменьшается производительность труда и ухудшается качество работы, может развиваться перенапряжение, а в отдельных случаях возникнуть срыв трудовой деятельности — дистресс.

В данном разделе проводится анализ условий труда в отделе разработки информационных систем с целью обеспечения безопасности и удобства, требуемых для работы инженера.

3.1.2 Характеристика помещения

Помещение находится в здании Московского Авиационного Института и представляет собой кафедральную лабораторию со следующими размерами:

- длина 6 м;
- ширина 4 м;
- высота 3.5 м.

Площадь: $6 \times 4 = 24 \text{ м}^2$.

Объём: $6 \times 4 \times 3.5 = 84 \text{ м}^3$.

Количество рабочих мест — 4.

Количество одновременно находящихся в помещении сотрудников не превышает 4 человек.

План помещения приведён на рисунке 8.




Рисунок 8 — План помещения

Нормативные требования к площади и объёму рабочих мест определены в [33]:

- площадь на одно рабочее место с ВДТ или ПЭВМ для взрослых пользователей должна составлять не менее 6 м^2 ;
- объём — не менее 20 м^3 .

Фактические значения на каждого сотрудника:

- площадь: $24/4 = 6 \text{ м}^2$;
- объём: $84/4 = 21 \text{ м}^3$.

Данные значения показывают, что кафедральная лаборатория полностью соответствует установленным нормам.

В помещении имеются 2 оконных проёма высотой 1,6 м и шириной 2,3 м, которые выходят на юго-запад.

Искусственное освещение представляет собой 6 светильников, расположенных параллельно окнам в 2 ряда.

3.1.3 Характеристика производственного процесса

Разработка программного обеспечения производится на ПЭВМ с подключенными к ней периферийными устройствами.

3.1.4 Характеристика используемого оборудования

В процессе разработки используется следующее оборудование:

а) ПЭВМ:

- 1) процессор Intel Core i5 3,60 ГГц;
- 2) оперативная память 8 Гб;
- 3) жёсткий диск 1 Тб;
- 4) напряжение питания 220 В.

б) ЖК монитор с диагональю 23 дюйма (58,42) ASUS VX239H:

- 1) частота 75 Гц;
- 2) яркость 250 кд/м²;
- 3) динамическая контрастность 8 000 000 : 1;
- 4) напряжение питания 220 В.

в) Клавиатура Logitech K330;

г) Мышь A7Tech X;

д) Принтер HP LaserJet 1005M:

- 1) напряжение питания 220 В.

3.1.5 Санитарно-гигиенические факторы

3.1.5.1 Микроклимат помещения

Микроклимат в рабочем помещении должен соответствовать [34].

Согласно [34], работа разработчика ПО относится к категории «Легкая – Ia», т.к. лёгкие физические работы — работы с расходом энергии не более 150 ккал (174 Вт), а категория Ia подразумевает энергозатраты до 120 ккал/ч (139 Вт).

Рабочее место разработчика ПО является постоянным, т.к. он находится на нём большую часть рабочего времени (более 50%).

Нормативные и фактические значения для категории работ «Легкая – Ia», лёгкие физические работы — работы с расходом энергии не более 150 ккал (174 Вт). Категория Ia подразумевает энергозатраты до 120 ккал/ч (139 Вт).

Рабочее место разработчика модели является постоянным, т.к. он находится на нём большую часть рабочего времени (более 50%).

Нормативные и фактические значения для категории работ «Легкая – Ia» и постоянного рабочего места приведены в таблице 13.

Таблица 13 — Значения характеристик микроклимата помещения

	Температура, °С	Относительная влажность, %	Скорость движения, м/с
Допустимые значения	22–24 — Холодный период 23–25 — Теплый период	40–60	0.1
Фактические значения	22–24 — Холодный период 25–30 — Теплый период	45–55	<0.1

Фактические значения параметров микроклимата данного помещения удовлетворяют допустимым значениям для холодного периода года. Во время теплого периода в помещении может преобладать повышенная температура из-за отсутствия кондиционера, который бы мог её регулировать.

3.1.5.2 Производственное освещение

Освещённость регламентируется [35].

Наименьший размер объекта различения в работе инженера составляет 0.3 мм. Объектом является символ, выводимый на экран монитора (наименьшим символом является точка). Зрительная работа относится к III разряду — высокая точность (наименьший размер объекта различения от 0.3 до 0.5 мм).

Контраст объекта с фоном средний, фон светлый, что соответствует подразряду б разряда III.

Требования к освещению помещений промышленных предприятий для подразряда б разряда III:

- При системе комбинированного освещения освещенность равна: всего — 1000 лк, в т.ч. от общего — 200 лк;
- При системе общего освещения освещённость равна 300 лк.

Система освещения в комнате общая, состоящая из 6 потолочных светильников ЛПО 46, в каждом из которых установлены 4 люминесцентные лампы ЛТБ мощностью 20 Вт и световым потоком 1100 лм. Светильники расположены в два ряда параллельно окнам. Фактическая освещенность составляет 275 лк, что полностью удовлетворяет нормативным значениям [35].

3.1.5.3 Шум

Источники шума в данном помещении: охлаждающие системы ПЭВМ (охлаждение процессоров).

Уровни шума на рабочих местах инженера ПЭВМ должны соответствовать [36].

Допустимые значения уровня шума при проектировании и программировании на рабочих местах в помещениях проектно-конструкторских бюро; расчётчиков, программистов вычислительных машин, в лабораториях для теоретических работ и обработки данных: не более 50 дБА.

Фактические значения уровня шума: не более 45 дБА, что подтверждается расчётами в разделе 3.3.

Согласно [36], значения уровня шума на рабочем месте удовлетворяют установленным требованиям.

3.1.5.4 Электромагнитное излучение

Во время работы ПЭВМ возникают электромагнитные поля, которые оказывают негативное влияние на организм человека.

Источниками электромагнитных полей на рабочем месте инженера являются системные блоки. Современные корпуса системных блоков ПЭВМ позволяют значительно ослабить излучения его элементов. Благодаря существующим достаточно строгим стандартам дозы рентгеновского излучения от современных мониторов и системных блоков не опасны для пользователей.

Документом, регламентирующим уровень электромагнитного излучения для ПЭВМ, является [33].

Согласно ему, напряжённости электрических и магнитных полей, энергетической нагрузки в течение рабочего дня не должны превышать значений, указанных в таблице 14.

Монитор ASUS VX239H соответствует стандарту [37], который устанавливает следующие предельные значения электромагнитного излучения:

- напряжённость электрического поля: в диапазоне 5Гц–2кГц не более 10 В/м, в диапазоне 2кГц–400кГц не более 1.0 В/м;
- напряжённость магнитного поля: в диапазоне 5Гц–2кГц не более 200 нТл, в диапазоне 2кГц–400кГц не более 25 нТл.

Таблица 14 — Предельные значения электромагнитного излучения.

Параметр	Предельные значения в диапазонах частот, МГц		
	от 0.06 до 3	св. 3 до 30	св. 30 до 300
$E_{\text{ПД}}, \text{В/м}$	500	300	80
$H_{\text{ПД}}, \text{А/м}$	50	—	—
$\text{ЭН}_{E_{\text{ПД}}}, (\text{В/м})^2 \cdot \text{ч}$	20000	7000	800
$\text{ЭН}_{H_{\text{ПД}}}, (\text{А/м})^2 \cdot \text{ч}$	200	—	—

Данные характеристики полностью соответствуют требованиям [33].

3.1.6 Электроопасность

В данном помещении используется оборудование, питающееся от сети переменного тока напряжением 220 В, частотой 50 Гц.

Согласно [38], помещение отдела разработки ИС относится к классу помещений без повышенной опасности поражения электрическим током: это сухое помещение с непроводящими полами, с нормальной температурой воздуха и влажностью, в нем отсутствует токопроводящая пыль.

Электрооборудование в помещении представлено мониторами и системными блоками ПЭВМ. Источником электрического поражения может быть металлический корпус системного блока при пробое изоляции, т.к. имеется напряжение 220 В, а в [39] допустимое напряжение и ток для аварийных режимов при времени воздействия более 1 секунды составляют 20 В и 6 мА.

3.1.7 Пожароопасность

В данном помещении имеются твердые горючие и трудногорючие вещества и материалы (книги, документы, деревянная мебель, оргтехника и т.д.), которые при взаимодействии с огнем будут гореть без взрыва. Также источником возгорания может быть электрическая проводка.

Согласно [40], данное помещение относится к классу Б и является пожароопасным.

3.1.8 Эргономические факторы

Требования к организации рабочих мест пользователей ПЭВМ изложены в [33].

Согласно [33], расстояние между рабочими столами с мониторами (в направлении тыла поверхности одного монитора и экрана другого монитора) должно быть не менее 2 м, а расстояние между боковыми поверхностями мониторов не менее 1.2 м.

Фактические значения (см. рисунок 8):

- расстояние между рабочими столами 2.1–2.5 м;
- расстояние между боковыми поверхностями мониторов 2.1-2.3 м.

Таким образом, размещение рабочих столов полностью соответствуют требованиям [33].

В помещении используется специальный стол — рабочая поверхность, изготовленная на заказ по выбранным заказчиком параметрам. Ее характеристики и нормативные значения указаны в таблице 15.

Таблица 15 — Характеристики используемого рабочего стола

Наименование параметра	Нормативное значение [33], мм	Фактическое значение, мм
Ширина рабочей поверхности	не менее 500	1200–2000
Глубина рабочей поверхности	не менее 800	800
Высота рабочей поверхности	не менее 725	800
Пространство для ног высотой	не менее 600	600
Глубина на уровне колен	не менее 450	450
Глубина на уровне вытянутых ног	не менее 650	650

Параметры стола полностью соответствуют требованиям [33].

В помещении используется офисное кресло БЮРОКРАТ Ch-G318AXN. Его характеристики и нормативные размеры указаны в таблице 16.

Таблица 16 — Характеристики используемого офисного кресла

Наименование параметра	Нормативное значение [33]	Фактическое значение
Ширина и глубина поверхности сиденья	не менее 400 мм	420 мм
Регулировка высоты поверхности сиденья	400–550 мм	440–570 мм
Регулировка углов наклона сиденья	вперед до 15° и назад до 5°	вперед до 15° и назад до 5°
Высота опорной поверхности спинки	300 ± 20 мм	310 мм
Ширина опорной поверхности спинки	не менее 380 мм	380 мм
Радиус кривизны горизонтальной плоскости опорной поверхности спинки	400 мм	400 мм
Угол наклона спинки в вертикальной плоскости	$\pm 30^\circ$	$\pm 30^\circ$
Регулировка расстояния спинки от переднего края сиденья	260–400 мм	260–450 мм
Стационарные или съёмные подлокотники	длина не менее 250 мм ширина 50–70 мм	длина 250 мм ширина 60 мм
Регулировка подлокотников по высоте над сиденьем	230 ± 30 мм	Нет
Регулировка внутреннего расстояния между подлокотниками	350–500 мм	420–500 мм

Параметры стула частично не соответствуют требованиям [33]: в данном рабо-

чем кресле отсутствует регулировка подлокотников по высоте над сидением.

3.1.9 Психофизиологические факторы

Факторами, оказывающими влияние на внимательность инженера и его производительность труда, в условиях его рабочего места являются:

- визуальные характеристики монитора (его яркость, контрастность, разрешение, частота обновления);
- напряженность работы;
- количество обрабатываемой информации — плотность воспринимаемых сигналов.

Используется ЖК монитор ASUS VX239H. Его фактические характеристики и нормативные значения [33] приведены в таблице 17.

Таблица 17 — Характеристики используемого ЖК монитора

Наименование фактора	Действительное значение	Нормативное значение [33]
Размер экрана по диагонали	58,42 см	не менее 31 см
Удалённость экрана	60 см	не менее 50 см
Частота обновления изображения	75 Гц	не менее 75 Гц
Контрастность	8 000 000:1	не менее 3:1
Яркость знака	250 кд/м ²	не менее 35 кд/м ²

Характеристики монитора полностью соответствуют требованиям [33].

Напряженность работы на основании данных таблицы классов условий труда по показателям напряженности трудового процесса [41] представлена в таблице 18.

Таблица 18 — Напряженность работы

Критерий	Характеристика	Напряженность трудового процесса
Содержание работы	Решение сложных задач по известным алгоритмам (работа по серии инструкций)	Напряженный труд 1 степени
Восприятие сигналов (информации и их оценка)	Восприятие сигналов с последующей комплексной оценкой взаимосвязанных параметров	Напряженный труд 2 степени
Степень сложности задания	Обработка, проверка и контроль за выполнением задания	Напряженность труда средней степени
Характер выполняемой работы	График с возможной корректировкой	То же
Длительность сосредоточенного наблюдения (в % от времени смены)	26–50%	—//—
Плотность сигнала за 1 час работы	176–300	Напряженный труд 1 степени
Число объектов одновременного наблюдения	6–10	Напряженность труда средней степени

Критерий	Характеристика	Напряженность трудового процесса
Размер объекта различения, мм, при длительном сосредоточенном наблюдении (% времени смены)	3–10 мм до 50% времени	То же
Степень ответственности	Ответственность за качество конечного результата	Напряженный труд 2 степени
Значимость ошибки	Влечет за собой дополнительные усилия в работе со стороны работника	Напряженность труда лёгкой степени
Продолжительность рабочего дня	8–9 часов	Напряженность труда средней степени

Среднее значение по данным критериям соответствует средней степени напряженности труда.

3.2 Мероприятия по обеспечению условий труда

Микроклимат в помещении в холодное время года обеспечивается с помощью системы центрального отопления. В летний же период времени в помещении не происходит регулирования температуры и влажности из-за отсутствия кондиционера. Рекомендуется установить, например, потолочный кондиционер Panasonic CS-A18BTP/CU-A18BVP5 с циркуляцией воздуха 840 м³/час.

Мероприятия по обеспечению требуемых условий по освещенности можно отнести к выбору ламп в источниках света. Часть цвет предметов освещенных люминес-

центными лампами может быть несколько искажён и быть неприятен человеку. Это, в свою очередь, вызывает усталость и напряженность глаз. Для предотвращения этого целесообразно использовать лампы с «трехполосным» и «пятиполосным» люминофором — веществом, способным преобразовывать поглощаемую им энергию в световое излучение. Это позволяет добиться более равномерного распределения излучения по видимому спектру, что приводит к более натуральному воспроизведению света. Данным параметрам соответствует лампа Philips Master TL-D De Luxe 36W/D65.

Уровень шума при использовании описанных ПЭВМ не превосходит норм, поэтому дополнительных мер для предотвращения излишнего шума не требуется. При покупке нового оборудования следует учитывать уровень шума от каждой новой единицы.

Обеспечение электробезопасности основано на применении устройств защитного отключения (УЗО). Данное устройство реагирует на ухудшение изоляции электропроводки: когда ток утечки повысится до предельной величины 30 мА, происходит отключение напряжения в течение 30 микросекунд. Целесообразно применять УЗО Legrand DX 06576.

Пожаробезопасность должна быть обеспечена при помощи обработки жидкостью от возгорания предметов мебели, инструктажа персонала на предмет мер предотвращения пожара или эвакуационных действий при пожаре, тщательной проверки оборудования на предмет повреждения проводов или оборудования.

3.3 Расчетная часть

3.3.1 Расчет уровня шума

Цель расчета — определить, соответствует ли фактический уровень шума в помещении нормативным значениям. Основными источниками шума в рассматриваемом помещении является аппаратура системных блоков ПЭВМ (кулер процессора).

Расчет производится в соответствии с [42].

План помещения с указанием рабочих мест и рабочей точки показан на рисунке 9

Будем считать, что оператор, находящийся в расчётной точке, располагается в зоне действия прямого звука. Тогда фактические значения уровней звукового давления




Рисунок 9 — План помещения с указанием рабочих мест и рабочей точки

в октановых полосах частот на расстоянии r от источника и суммарных значений от нескольких источников рассчитываются по формулам (27) и (28).

$$L_i = L_{W_i} - 20 \cdot \log r_i - 11; \quad (27)$$

$$L_{\Sigma} = 10 \cdot \log \sum_{i=1}^n 10^{0.1 \cdot L_i}, \quad (28)$$

где L_{W_i} — уровень звуковой мощности i -го источника.

Допустимые уровни звукового давления в расчётной точке представлены в соответствии с [33].

Расстояния от рабочих мест до рабочей точки:

$$r_1 = 1.8 \text{ м}, r_2 = 1.8 \text{ м}, r_3 = 3.1 \text{ м}, r_4 = 1.2 \text{ м}.$$

Уровни звукового давления для источников шума 1-4 (PM1-PM4) для уровня звуковой мощности кулера $L = 38$ дБ и среднегеометрической частоты 500 Гц:

$$L_1 = 38 - 20 \cdot \log 1.8 - 11 = 31.9 \text{ дБ};$$

$$L_2 = 38 - 20 \cdot \log 1.8 - 11 = 31.9 \text{ дБ};$$

$$L_3 = 38 - 20 \cdot \log 3.1 - 11 = 27.2 \text{ дБ};$$

$$L_4 = 38 - 20 \cdot \log 1.2 - 11 = 38.5 \text{ дБ}.$$

В этом случае уровень звукового давления от 4 источников:

$$L_{\Sigma} = 10 \cdot \log(10^{0.1 \cdot 31.9} + 10^{0.1 \cdot 31.9} + 10^{0.1 \cdot 27.2} + 10^{0.1 \cdot 38.5}) = 38.5 \text{ дБ}.$$

Уровни звукового давления для источников шума 1-4 (PM1-PM4) для уровня звуковой мощности кулера $L = 37$ дБ и среднегеометрической частоты 1000 Гц:

$$L_1 = 37 - 20 \cdot \log 1.8 - 11 = 30.9 \text{ дБ};$$

$$L_2 = 37 - 20 \cdot \log 1.8 - 11 = 30.9 \text{ дБ};$$

$$L_3 = 37 - 20 \cdot \log 3.1 - 11 = 26.2 \text{ дБ};$$

$$L_4 = 37 - 20 \cdot \log 1.2 - 11 = 37.5 \text{ дБ}.$$

В этом случае уровень звукового давления от 4 источников:

$$L_{\Sigma} = 10 \cdot \log(10^{0.1 \cdot 30.9} + 10^{0.1 \cdot 30.9} + 10^{0.1 \cdot 26.2} + 10^{0.1 \cdot 37.5}) = 37.5 \text{ дБ}.$$

Уровни звукового давления источников шума для остальных частот рассчитываются аналогично. Результаты расчётов сведены в таблицу 19.

Уровень шума в расчетной точке не превышает допустимые значения, таким образом, не требуются никакие мероприятия по снижению шума в помещении.

3.4 Вывод

В разделе «Охрана труда и окружающей среды» был проведен анализ условий труда инженера-программиста по следующим факторам: санитарно-гигиеническим, эргономическим, психофизическим; была проведена оценка помещения по электроопасности и пожароопасности. Также были предложены мероприятия по обеспечению требований предъявляемых к эргономическим характеристикам рабочего места. В расчетной части был осуществлен расчет уровня шума в помещении, в результате которого были получены значения, не превышающие допустимые.

По всем перечисленным факторам было выявлено соответствие нормам и требованиям ГОСТов, СанПиНов и СНиПу.

Таблица 19 — Сводная таблица значений уровней шума

Среднегеометрическая частота, Гц	63	125	250	500	1000	2000	4000	8000
Уровень звуковой мощности кулера блока питания, дБ	35	37,5	37,5	38	37	36,5	36,5	35,5
Уровень звукового давления от источника шума 1 (PM1) при $r = 1.8$ м, дБ	28.9	31.4	31.4	31.9	30.9	30.4	30.4	29.4
Уровень звукового давления от источника шума 2 (PM2) при $r = 1.8$ м, дБ	28.9	31.4	31.4	31.9	30.9	30.4	30.4	29.4
Уровень звукового давления от источника шума 3 (PM3) при $r = 3.1$ м, дБ	24.2	26.7	26.7	27.2	26.2	25.7	25.7	24.7
Уровень звукового давления от источника шума 4 (PM4) при $r = 1.2$ м, дБ	32.4	34.9	34.9	35.4	34.4	33.9	33.9	32.9
Уровень звукового давления от 4 источников шума, дБ	35.5	38	38	38.5	37.5	37	37	36
Допустимый уровень звукового давления в расчетной точке (РТ), дБ	71	61	54	49	45	42	40	38

Заключение

здесь должно быть заключение

Список использованных источников

1. Jennions I. K. Integrated Vehicle Health Management: Perspectives on an Emerging Field. SAE International, 2011. 188 p.
2. Yairi T., Kato Y., Hori K. Fault Detection by Mining Association Rules from House-keeping Data // Proceedings of the 6th International Symposium on Artificial Intelligence and Robotics & Automation in Space (i-SAIRAS 2001). Quebec, Canada: Canadian Space Agency, 2001.
3. Fayyad U., Piatetsky-Shapiro G., Smyth P. From Data Mining to Knowledge Discovery in Databases // AI Magazine. 1996. Vol. 17, no. 3. P. 37–54.
4. Chandola V., Banerjee A., Kumar V. Anomaly Detection: A Survey // ACM Computing Surveys. 2009. Vol. 41, no. 3. P. 15:1–15:58.
5. Hawkins D. M. Identification of Outliers. New York, NY, USA: Chapman and Hall, 1980. 188 p.
6. Деревяненко В.В. Применение Data Mining в космических приложениях // Исследования Наукограда. 2012. № 1. С. 47–51.
7. General Purpose Data-Driven System Monitoring for Space Operations / D. Iverson, R. Martin, M. Schwabacher et al. // AIAA Infotech@Aerospace Conference. 2009.
8. Iverson D. Inductive System Health Monitoring // Proceedings of The 2004 International Conference on Artificial Intelligence (IC-AI'04). Las Vegas, NV, USA: CSREA Press, 2004.
9. Comparison of Unsupervised Anomaly Detection Methods for Systems Health Management Using Space Shuttle Main Engine Data / R. Martin, M. Shwabacher, N. Oza et al. // Proceedings of the 54th Joint Army-Navy-NASA-Air Force Propulsion Meeting. Denver, CO, USA: 2007.
10. Columbia Accident Investigation Board: Report: Washington, D.C., USA: NASA, 2003.

11. Iverson D. System Health Monitoring for Space Mission Operations // Proceedings of The SpaceOps 2008 Conference (European Space Agency, AIAA). Heidelberg, Germany: 2008.
12. Гиродин. Материал из Википедии — свободной энциклопедии. URL: <http://ru.wikipedia.org/wiki/Гиродин> (дата обращения: 20.11.2013).
13. Fukushima Y. Telemetry Data Mining with SVM for Satellite Monitoring // Modern Telemetry / Ed. by O. Krejcar. InTech, 2011. P. 95–114.
14. Schwabacher M. Machine Learning for Rocket Propulsion Health Monitoring // Proceedings of the SAE World Aerospace Congress. Vol. 114-1. Dallas, TX, USA: Society of Automotive Engineers, 2005. P. 1192–1197.
15. Bay S. D., Schwabacher M. Mining Distance-Based Outliers in Near Linear Time with Randomization and a Simple Pruning Rule // Proceedings of the ninth ACM SIGKDD international conference on Knowledge discovery and data mining (KDD '03). New York, NY, USA: ACM Press, 2003. P. 29–38.
16. Knorr E. M., Ng R. T. Algorithms for Mining Distance-Based Outliers in Large Datasets // Proceedings of the 24rd International Conference on Very Large Data Bases (VLDB '98). San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 1998. P. 392–403.
17. Tao Y., Xiao X., Zhou S. Mining Distance-Based Outliers from Large Databases in Any Metric Space // Proceedings of the 12th ACM SIGKDD international conference on Knowledge discovery and data mining (KDD '06). Philadelphia, PA, USA: ACM Press, 2006. P. 394–403.
18. Angiulli F., Fasseti F. Very Efficient Mining of Distance-Based Outliers // Proceedings of the sixteenth ACM conference on Conference on information and knowledge management (CIKM '07). New York, NY, USA: ACM Press, 2007. P. 791–800.
19. Ramaswamy S., Rastogi R., Shim K. Efficient Algorithms for Mining Outliers from Large Data Sets // Proceedings of the 2000 ACM SIGMOD international conference


- on Management of data (SIGMOD '00). New York, NY, USA: ACM Press, 2000. P. 427–438.
20. RuleQuest Research. Checking Data Quality with GritBot. 2005. URL: <http://http://www.rulequest.com/gritbot-info.html> (дата обращения: 19.11.2013).
 21. Eberle W., Holder L., Cook D. Identifying Threats Using Graph-based Anomaly Detection // Machine Learning in Cyber Trust: Security, Privacy, and Reliability / Ed. by J. J. Tsai, P. S. Yu. Springer, 2009. P. 97–98.
 22. Quinlan J. R. C4.5: Programs for Machine learning. San Mateo, CA, USA: Morgan Kaufmann Publishers Inc., 1993. 302 p.
 23. Королев В.Ю. ЕМ-алгоритм, его модификации и их применение к задаче разделения смесей вероятностных распределений. Теоретический обзор. М.: ИПИ РАН, 2007. С. 102.
 24. Martin R. A. Unsupervised Anomaly Detection and Diagnosis for Liquid Rocket Engine Propulsion // Proceedings of the IEEE Aerospace Conference. Big Sky, MT, USA: 2007.
 25. Pearl J. Causality: Models, Reasoning, and Inference. 2nd edition. Cambridge, UK: Cambridge University Press, 2009. 464 p.
 26. Hill D., Minsker B., Amir E. Real-time Bayesian Anomaly Detection for Environmental Sensor Data // Proceedings of the 32nd Conference of the International Association of Hydraulic Engineering & Research (IAHR '07). 2007.
 27. Лифшиц Юрий. Алгоритмы для интернета. Курс лекций. СПб.: ПОМИ РАН — СПбГУ ИТМО, 2006.
 28. Воронцов К.В. Машинное обучение. Курс лекций. М.: Школа анализа данных Яндекса, 2009.
 29. Vlasveld Roemer. Introduction to One-class Support Vector Machines. 2013. URL: <http://rvlasveld.github.io/blog/2013/07/12/introduction-to-one-class-support-vector-machines/> (дата обращения: 25.11.2013).

30. Bradley P. S., Fayyad U. M. Refining Initial Points of K-means Clustering // Proceedings of the International Conference on Machine Learning (ICML-98). San Mateo, CA, USA: Morgan Kaufmann Publishers Inc., 1998. P. 91–99.
31. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise / M. Ester, H.-P. Kriegel, J. Sander et al. // Proceedings of 2nd International Conference on Knowledge Discovery and Data Mining (KDD-96). Menlo Park, CA, USA: AAAI Press, 1996. P. 226–231.
32. Экономическое обоснование дипломных проектов (работ) по приборо- и радио-приборостроению / Панагушин В.П., Ковалева Т.С., Малютина О.А. [и др.]; под ред. Панагушина В.П. М.: ИВАКО Аналитик, 2008. 44 с.
33. СанПиН 2.2.2/2.4.1340–03 (с изменениями от 25 апреля 2007 г.) «Гигиенические требования к персональным электронно-вычислительным машинам и организации работы». М.: Минздрав России, 2003. 32 с.
34. ГОСТ 12.1.005–88 ССБТ «Общие санитарно-гигиенические требования к воздуху рабочей зоны». М.: ИПК Издательство стандартов, 2002. 71 с.
35. СНиП 23-05-95 «Естественное и искусственное освещение». М.: Минстрой России, 1995. 59 с.
36. ГОСТ 12.1.003–83 «Шум. Общие требования безопасности». М.: ИПК Издательство стандартов, 1983. 13 с.
37. The Swedish Confederation Of Professional Employees. TCO '03. 2005. URL: <http://www.dtic.ua.es/ibis/recursos/normativas/TCO03CRT.pdf> (дата обращения: 11.11.2013).
38. Правила устройства электроустановок. Издание седьмое. М.: Минэнерго России, 2002. 222 с.
39. ГОСТ 12.1.038–82 «Электробезопасность. Предельно допустимые значения напряжений прикосновения и токов». М.: ИПК Издательство стандартов, 1988. 5 с.

40. ГОСТ 12.1.004–91 «Пожарная безопасность. Общие требования». М.: ИПК Издательство стандартов, 1996. 83 с.
41. Р 2.2.2006–05 «Руководство по гигиенической оценке факторов рабочей среды и трудового процесса. Критерии и классификация условий труда». М.: Минздрав России, 2005. 156 с.
42. Бобков Н.И., Голованова Т.В. Охрана труда на ВЦ. Методическими указаниями к дипломному проектированию. М.: МАИ, 1991. 16 с.
43. Introduction to Algorithms / T. H. Cormen, C. E. Leiserson, R. L. Rivest et al. 3rd edition. Cambridge, MA, USA: The MIT Press, 2009. P. 151–169.
44. Knuth D. E. The Art of Computer Programming. Volume 2, Seminumerical Algorithms. MA, USA: Addison-Wesley, 1969. P. 124–125.
45. ГОСТ 2.105–95 «Единая система конструкторской документации. Общие требования к текстовым документам». М.: Стандартинформ, 2005. 29 с.
46. ГОСТ 7.1–2003 «Библиографическая запись. Библиографическое описание. Общие требования и правила составления». М.: ИПК Издательство стандартов, 2004. 166 с.
47. ГОСТ 7.32–2001 «Отчет о научно-исследовательской работе. Структура и правила оформления». М.: ИПК Издательство стандартов, 2001. 22 с.


ПРИЛОЖЕНИЕ А

Блок-схема ЕМ-алгоритма для GMM




ПРИЛОЖЕНИЕ Б

Блок-схема процесса обучения IMS




ПРИЛОЖЕНИЕ В

Блок-схема процесса мониторинга IMS




ПРИЛОЖЕНИЕ Г

Блок-схема процесса обучения разрабатываемого метода




ПРИЛОЖЕНИЕ Д

Блок-схема процесса создания базы кластеров для каждого режима работы системы (для разрабатываемого метода)



ПРИЛОЖЕНИЕ Е

Блок-схема процесса обучения разрабатываемого метода



ПРИЛОЖЕНИЕ Ж

Исходный код

Листинг Ж.1 — Псевдкод алгоритма Orca

Входные данные: $n \geq 0$

Выходные данные: $y = x^n$

```
1:  $y \leftarrow 1$ 
2:  $X \leftarrow x$ 
3:  $N \leftarrow n$ 
4: до тех пор, пока  $N \neq 0$  выполнять
5:   если  $N$  is even то
6:      $X \leftarrow X \times X$ 
7:      $N \leftarrow N/2$ 
8:   иначе { $N$  is odd}
9:      $y \leftarrow y \times X$ 
10:     $N \leftarrow N - 1$ 
11:   конец
12: конец цикла
```

```
foreach ( var x in values )
{
    int i = x.Key;
    Console.WriteLine( "Key: {0}", i );
}
```

ПРИЛОЖЕНИЕ 3

Графические материалы

тут должны быть слайды